

求解作业车间调度问题的改进混合灰狼优化算法*

姚远远, 叶春明

(上海理工大学 管理学院, 上海 200093)

摘要: 灰狼优化算法(GWO)是目前一种比较新颖的群智能优化算法,具有收敛速度快、寻优能力强等优点。将灰狼优化算法用于求解复杂的作业车间调度问题,与布谷鸟搜索算法进行比较研究,验证了标准 GWO 算法求解经典作业车间调度问题的可行性和有效性。在此基础上,针对复杂作业车间调度问题难以求解的特点,对标准 GWO 算法进行改进,通过进化种群动态、反向学习初始化种群以及最优个体变异三个方面的改进操作,测试结果表明,改进后的混合灰狼优化算法能够有效跳出局部最优值,找到更好的解,并且结果鲁棒性更强。

关键词: 灰狼优化算法; 作业车间调度; 最小化最大完工时间; 混合算法

中图分类号: TP301.6

文献标志码: A

文章编号: 1001-3695(2018)05-1310-05

doi:10.3969/j.issn.1001-3695.2018.05.007

Solving Job-Shop scheduling problem using improved hybrid grey wolf optimizer

Yao Yuanyuan, Ye Chunming

(Business School, University of Shanghai for Science & Technology, Shanghai 200093, China)

Abstract: Grey wolf optimizer(GWO) was currently one of the latest proposed swarm intelligence algorithms with the advantages of fast convergence rate and better optimization performance. Firstly this paper benchmarked the original GWO algorithm on 11 well-known Job-Shop scheduling test instances, and verified the results by a comparative study with cuckoo search (CS). The results show that the GWO algorithm is able to provide very competitive results compared to CS. In order to solve complex and large scale Job-Shop scheduling problems, it proposed an improved hybrid grey wolf optimizer (IGWO) by using evolutionary population dynamics (EPD) method, opposition-based learning strategy and mutation operator. Then it benchmarked the proposed IGWO algorithm on seven large scale test instances. It compared the results to the original GWO algorithm for verification. It demonstrates that the proposed algorithm is able to significantly improve the performance of the GWO algorithm for solving production scheduling problem in terms of exploration, local optima avoidance, exploitation and robustness.

Key words: grey wolf optimizer; Job-Shop scheduling; makespan minimization; hybrid algorithm

0 引言

生产调度是指在时间上对一组可用的制造资源,即机器进行加工任务的安排,将工件分配至相应的机器上,确定各机器上加工操作的加工次序和开工时间,使得某一性能指标最优。在执行这些加工任务时需要满足各种约束条件。因此,生产调度问题可表述为在一些等式或不等式约束构成的离散解空间中,寻找目标函数值的最优解。它是一类重要的组合优化问题,运筹学称之为排序问题。除少数特殊问题,大部分生产调度问题的计算复杂度为 NP-hard,存在优化求解的困难。有效的调度优化算法能使现代商业领域增加产出、减少周转时间、减少库存,最终减少生产费用、增加利润和提升客户满意度。因此,调度优化算法性能的好坏对这些行业的高效运转有重要影响,其研究具有重要的理论意义和实用价值^[1]。作业车间调度问题是所有生产调度中最复杂、最困难,也是更具一般性的问题之一,本文将对作业车间调度问题进行调度优化算法的研究。

灰狼优化算法(grey wolf optimizer, GWO)是 Mirjalili 等人^[2]于 2014 年提出的一种基于种群的随机优化算法。该算

法通过模仿自然界灰狼种群领导层级和捕食行为机制提出,通过对 29 个连续函数优化问题的测试,结果表明 GWO 在求解精度和稳定性上要明显优于 PSO、DE 和 GSA 等算法。为增强 GWO 算法的全局搜索能力, Saremi 等人^[3]对最初的 GWO 算法进行改进,在原始算法中引入进化种群动态操作(evolutionary population dynamics, EPD)提出一种混合 GWO 算法,函数优化问题的测试结果表明新算法性能得到显著改善。2016 年, Mirjalili 等人^[4]又提出了一种解决多目标函数优化问题的灰狼优化算法,灰狼优化算法一经提出就被大量引用。Lu 等人^[5,6]使用多目标灰狼优化算法解决焊装生产中的真实离散调度问题。吕新桥等人^[7]将改进的灰狼优化算法用于求解置换流水线车间调度问题。陈昌帅^[8]在灰狼优化算法的基础上引入转换函数,提出一种解决离散空间组合优化问题的二进制灰狼优化算法。

目前,灰狼优化算法多用于连续函数问题的优化研究,在作业车间调度这类较复杂的离散组合优化问题方面的应用研究还比较少。本文将首先验证标准 GWO 算法求解经典作业车间调度问题的可行性和有效性,并与布谷鸟搜索算法进行对比。在此基础上,针对复杂作业车间调度问题难以求解的特点,对标准 GWO 算法进行改进,进一步提高其求解复杂调度

收稿日期: 2017-01-05; 修回日期: 2017-02-26 基金项目: 国家自然科学基金资助项目(71271138); 上海理工大学科技发展项目(16KJFZ028); 上海市高原学科项目“管理科学与工程”(GYXK1201)

作者简介: 姚远远(1989-), 女, 河南灵宝人, 博士研究生, 主要研究方向为生产调度、智能算法(tracy_yao11@163.com); 叶春明(1964-), 男, 安徽宣城人, 教授, 博导, 主要研究方向为工业工程、生产调度等。

问题的优化性能。

1 作业车间调度问题的数学描述

作业车间调度问题是最困难的约束组合优化问题和典型的 NP-hard 问题,其特点是没有一个有效的算法能在多项式时间内求出其最优解。作业车间调度问题研究^[9] n 个工件在 m 台机器上的加工过程, O_{ij} 表示第 i 个工件在第 j 台机器上的操作,相应的操作时间 p_{ij} 为已知,事先给定各工件在各机器上的加工次序,即技术约束条件,要求确定与技术约束条件相容的各机器上所有工件的加工次序,使加工性能指标达到最优。通常还假定每一时刻每台机器只能加工一个工件,且每个工件只能被一台机器加工,同时加工过程为不间断,机器间缓冲区容量为无限。

常用的作业车间调度问题的建模有整数规划、线性规划和析取图模型三种方法。本文将对以最大完工时间最短为优化指标的作业车间调度问题进行研究,并采用 Bake 给出的 JSP 整数规划模型。该调度问题的数学模型描述如下^[10]:

$$\text{目标函数: } \min \max_{1 \leq k \leq m} \{ \max_{1 \leq i \leq n} C_{ik} \} \quad (1)$$

约束条件:

$$C_{ik} - p_{ik} + M(1 - a_{ihk}) \geq C_{ih} \quad i = 1, 2, \dots, n; h, k = 1, 2, \dots, m \quad (2)$$

$$C_{jk} - C_{ik} + M(1 - x_{ijk}) \geq p_{jk} \quad i, j = 1, 2, \dots, n; k = 1, 2, \dots, m \quad (3)$$

$$C_{ik} \geq 0 \quad i = 1, 2, \dots, n; k = 1, 2, \dots, m \quad (4)$$

$$x_{ijk} = 0 \text{ 或 } 1 \quad i, j = 1, 2, \dots, n; k = 1, 2, \dots, m \quad (5)$$

式(1)表示目标函数,即最小化最大完成时间;式(2)表示工艺约束条件决定的每个工件的操作先后顺序;式(3)表示加工每个工件的每台机器的先后顺序。 C_{ik} 和 p_{ik} 分别为工件 i 在机器 k 上的完成时间和加工时间; M 是一个足够大的正数; a_{ihk} 和 x_{ijk} 分别为指示系数和指示变量,其含义为

$$a_{ihk} = \begin{cases} 1 & \text{若机器 } h \text{ 先于机器 } k \text{ 加工工件 } i \\ 0 & \text{非上述情况} \end{cases} \quad (6)$$

$$x_{ijk} = \begin{cases} 1 & \text{若工件 } i \text{ 先于工件 } j \text{ 在机器 } k \text{ 上加工} \\ 0 & \text{非上述情况} \end{cases} \quad (7)$$

2 改进混合灰狼优化算法

2.1 基本灰狼优化算法

作为一种仿生群体智能优化算法,灰狼优化算法通过模仿自然界灰狼群体的社会领导层级机制和捕食行为提出。与其他元启发式算法类似,该算法首先随机产生一组候选解,每次迭代选出最好的三个候选解称为 alpha、beta 和 delta,由它们带领整个种群朝着最优解方向移动。种群中的其他个体 omega 追随 alpha、beta 和 delta 搜寻更好的解。灰狼种群的包围捕食行为可以通过下述数学式进行描述。

$$D = |C \cdot X_p(t) - X(t)| \quad (8)$$

$$X(t+1) = X_p(t) - A \cdot D \quad (9)$$

$$A = 2a \cdot r_1 - a \quad (10)$$

$$C = 2 \cdot r_2 \quad (11)$$

$$a = 2 - t \cdot (2/t_{\max}) \quad (12)$$

其中: t 为当前迭代次数; t_{\max} 为种群的最大迭代次数; A 和 C 是协同系数向量; X_p 表示猎物的位置向量; X 表示灰狼的位置向量; a 随着迭代过程从 2~0 线性递减; r_1 和 r_2 是 $[0, 1]$ 中的随机数向量。为了找到问题的最优解,每个 omega 灰狼个体的位置更新式如下:

$$D_\alpha = |C_1 \cdot X_\alpha - X| \quad (13)$$

$$D_\beta = |C_2 \cdot X_\beta - X| \quad (14)$$

$$D_\delta = |C_3 \cdot X_\delta - X| \quad (15)$$

$$X_1 = X_\alpha - A_1 \cdot (D_\alpha) \quad (16)$$

$$X_2 = X_\beta - A_2 \cdot (D_\beta) \quad (17)$$

$$X_3 = X_\delta - A_3 \cdot (D_\delta) \quad (18)$$

$$X(t+1) = \frac{X_1 + X_2 + X_3}{3} \quad (19)$$

另外,Mirjalili 等人^[2]指出在上述公式中参数 A 和 C 决定灰狼优化算法的全局搜索和局部搜索,当 $|A| > 1$ 时算法进行全局搜索,当 $|A| < 1$ 时进行局部搜索。参数 C 的随机产生可以有效避免算法陷入局部最优。虽然上述操作可以在一定程度上提高收敛效率和避免早熟收敛,但是由于灰狼优化算法的种群寻优过程本质上是由最优的三个候选解 alpha、beta 和 delta 主导,该算法往往倾向于早熟收敛,陷入局部最优值不再跳出。因此,如果在该算法中对最优候选解进行一定的变异操作,能够有效帮助算法找到更好的解。

2.2 改进混合灰狼优化算法

2.2.1 进化种群动态操作

Saremi 等人^[3]在 GWO 算法中引入进化种群动态操作 (EPD),就是将种群中差的个体移除,已有研究证明 EPD 能够改善整个种群适应度的中值,是一种改进元启发式算法性能的简单有效方法。在混合灰狼优化算法的每一次迭代中,通过 EPD 操作将种群中差的一半个体位置清除,然后在四个位置以相等概率重新随机生成它们的新位置。这四个位置分别是位于 alpha、beta 和 delta 周围(改善整个种群中值),以及搜索空间的随机位置(避免陷入局部最优)。由于 Saremi 等人提出的混合灰狼优化算法是针对连续函数优化问题设计,不能直接用于求解离散的组合优化问题。所以,本文对该操作进行改进,改进后的四个位置更新式如下:

$$X(t+1) = X_\alpha(t) + L \otimes \text{randn} \quad (20)$$

$$X(t+1) = X_\beta(t) + L \otimes \text{randn} \quad (21)$$

$$X(t+1) = X_\delta(t) + L \otimes \text{randn} \quad (22)$$

$$X(t+1) = \text{rand} \quad (23)$$

其中, $X_\alpha(t)$ 、 $X_\beta(t)$ 和 $X_\delta(t)$ 分别表示 alpha、beta 和 delta 个体的当前位置; rand 是 $[0, 1]$ 中的随机数向量; randn 是服从标准正态分布的随机数向量,可以是正或负值; \otimes 代表矢量运算; L 表示步长向量。此处引入布谷鸟搜索算法中的 Lévy 飞行方式^[11],可以有效防止 GWO 算法早熟收敛,其计算公式为

$$L = \frac{u}{|v|^{1/\beta}} \quad (24)$$

其中: β 是一个 $[1, 2]$ 的参数,此处取 $\beta = 1.5^{[11,16]}$; u 和 v 服从正态分布。

$$u \sim N(0, \sigma_u^2), v \sim N(0, \sigma_v^2) \quad (25)$$

$$\text{其中: } \sigma_u = \left\{ \frac{\Gamma(1+\beta) \sin(\pi\beta/2)}{\Gamma[(1+\beta)/2] \beta 2^{(\beta-1)/2}} \right\}^{1/\beta}, \sigma_v = 1 \quad (26)$$

2.2.2 反向学习初始化种群

对基于种群迭代的群体智能优化算法来说,初始种群的好坏直接影响着算法的全局搜索效率和解的质量,多样性较好的初始种群对提高算法的寻优性能有很大帮助。然而,标准 GWO 算法在迭代开始前通过随机初始化产生种群个体,难以确保初始种群的多样性,从而在一定程度上影响了算法的搜索效率。本文将采用反向学习策略来产生初始种群。Tizhoosh^[12]在 2005 年提出了反向学习策略,目前已在 GA、DE、ACO 等群体智能优化算法中得到了成功的应用。采用反向学习策略产生初始种群个体的具体操作步骤如下:

a) 在搜索空间中随机初始化 N 个灰狼个体的位置 $x_{i,j}$ ($i = 1, 2, \dots, D; j = 1, 2, \dots, N$) 作为初始种群 P_1 。在作业车间调度问题的编码中 $x_{i,j} \in [0, 1]$ 中的随机数, D 为每个灰狼个体的维数, 即工序总数; N 为种群个数。

b) 生成初始种群 P_1 中每个灰狼个体 $x_{i,j}$ 的反向个体 $x_{i,j}'$ 构成反向种群 P_2 , $x_{i,j}' = 1 - x_{i,j}$ 。

c) 合并种群 P_1 和 P_2 , 将 $2N$ 个灰狼个体按照适应度值进行升序排序, 选取适应度值前 N 个灰狼个体作为最终的初始种群。

2.2.3 变异算子

由于基于精英保存策略, 在 GWO 算法进化后期, 群体中所有灰狼个体均向最优个体区域靠近, 从而导致种群丧失多样性, 如果此时当前最优灰狼个体 α 为局部最优解, 则 GWO 算法将陷入局部最优, 出现早熟收敛现象, 这也是很多群体智能优化算法的弊端。为了降低 GWO 算法出现早熟现象和陷入局部最优值的概率, 本文对群体中当前最优灰狼个体 α 进行多样性变异操作, 其原理是^[13]: 对最优个体 α 中的每一维元素以 $1/D$ 的概率进行变异。变异操作公式为

$$X_{\alpha}(t+1) = X_{\alpha}(t) + \varepsilon \cdot \text{rand} \cdot K \quad (27)$$

其中: ε 是一个很小的正数, 经过测试此处 $\varepsilon = 0.01$ 算法优化效果最好; rand 是 $[0, 1]$ 中的随机数向量; K 是一个 0 和 1 组成的向量, 各维元素 K_j 的取值公式如下所示, r_j 是 $[0, 1]$ 的一个随机数, 当 $r_j \leq 1/D$, $K_j = 1$, 否则 $K_j = 0$ 。

$$K_j = \begin{cases} 1 & r_j \leq 1/D \\ 0 & r_j > 1/D \end{cases} \quad (28)$$

通过对标准 GWO 算法进行进化种群动态、反向学习初始化种群, 以及最优个体变异三方面的改进操作, 改进后的混合灰狼优化算法拥有更佳的寻优性能, 同时跳出局部最优解的能力更强。本文将改进后的混合灰狼优化算法简称为 IGWO, 运用所提出的 IGWO 算法求解作业车间调度问题的算法流程如图 1 所示。

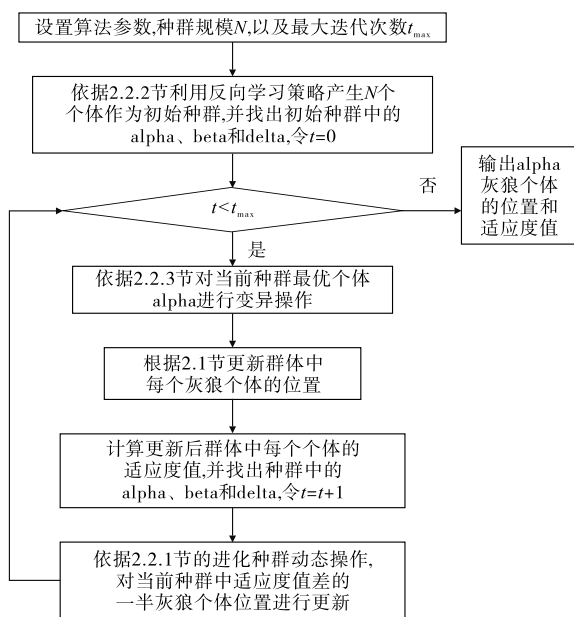


图1 IGWO算法流程

3 仿真实验及分析

3.1 Job-Shop 标准测试问题

在生产调度的研究过程中, 为了判断不同算法各自的优缺点, 需要用相同的问题去测试。因此, 诞生了标准问题。标准问

题提供了一个关于评判所有求解作业车间调度问题算法的共同标准, 它使这些算法得以被测试和比较。由于标准问题有着不同的维数和困难程度, 所以使用这些标准问题测试很容易确定一个算法的性能, 从而可以找出算法在哪些地方需要改进。

在著名的 OR-Library 中收集了大量的用于运筹学问题研究的测试数据集, 该数据库一直由 Beasley 负责维护 (<http://people.brunel.ac.uk/~mastijb/jeb/info.html>)。在其子目录中可以找到许多经典调度问题的实例数据, 其中 Job-Shop 调度问题测试实例网址中包含了 82 个经典问题的测试数据 (<http://people.brunel.ac.uk/~mastijb/jeb/orlib/files/jobshop1.txt>)。典型的 Job-Shop 调度问题有 FT、LA、ABZ、ORB、SWV、YN、TD 和 DMU 类等, 其中以 FT、LA 和 TD 类调度问题的研究居多。Fisher 和 Thompson 在 1963 年提出了 FT 问题, 包括 FT06、FT10 和 FT20。其中, FT10 问题是最著名的标准问题实例, 从 1963 年问题被提出起, 经过众多学者的努力, 历经 26 年才得到 FT10 问题的最优解, 其最小完成时间为 930 s (本文将时间单位统一为 min)。LA 问题由 Lawrence 于 1984 年给出, 包括 40 个问题, 命名为 LA1 ~ LA40, 分别有八种不同的规模, 每种规模包含五个问题。为了测试 GWO 算法求解调度问题的寻优性能, 本文选择文献[9]后附录中的 11 个 Job-Shop benchmark 问题测试实例, 并将基本的 GWO 算法与近年来很受欢迎的布谷鸟搜索算法^[14]进行对比研究。

3.2 GWO 和 CS 算法的比较

布谷鸟搜索算法 (cuckoo search, CS) 由 Yang 等人^[15,16]于 2009 年提出, 该算法基于布谷鸟的巢寄生繁育行为和鸟类、果蝇等的莱维飞行行为特征提出, 具有控制参数少和能够有效保持局部搜索及全局搜索之间平衡两个优点, 已有研究表明该算法性能优于粒子群算法和遗传算法。为了验证 GWO 算法求解调度问题的可行性, 本文选取了 11 个 Job-Shop 标准测试实例 (包含各种不同的问题规模), 并将其测试结果与 CS 算法进行对比。实验仿真环境为操作系统 Windows 7、处理器 Intel Core i5-4210M CPU @ 2.60GHz、内存 4 GB, 采用 MATLAB R2012a 实现算法编程。算法参数设置如下: 布谷鸟搜索算法中, 鸟窝个数 $n = 30$, 宿主发现外来鸟蛋的概率 $P_a = 0.25$; 灰狼优化算法中灰狼种群个数为 30。最大迭代次数均为 $\max T = 500$, 每种算法各独立运行 30 次, 测试结果如表 1 所示。

表 1 的结果表明, 对于机器数较少的简单调度问题如 FT06、LA01、LA06 和 LA11, GWO 和 CS 算法都可以快速找到问题的最优值及其调度方案, FT06 和 LA01 测试实例的甘特图如图 2 所示。然而, 当机器数较大时, GWO 和 CS 算法都难以找到问题的最优值, 寻优成功率都为 0%, 但是从 Δ_{\min} 和 Δ_{avg} 这两个指标可以看出 GWO 的求解效果更好, 均优于 CS 算法。另外, 本文针对其中六个具有代表性的测试实例分别给出了它们的迭代曲线图, GWO 和 CS 算法的寻优曲线如图 3 所示。从图 3 中可以明显看出 GWO 算法的收敛速度比 CS 算法快, 并且寻优性能更优越。但是就 Δ_{std} 指标而言, CS 比 GWO 算法求解结果更稳定, 鉴于该发现, 本文将在改进后的混合灰狼优化算法中加入 CS 算法的某些特性, 以改善 GWO 算法求解结果的稳定性。通过对以上 GWO 算法求解 Job-Shop 问题的测试分析发现, 当机器数越大, 问题越难求解。对于简单的调度问题, 两种算法都能很容易找到最优值, 对于复杂问题 GWO 算法的求解效果更好, 求解结果更接近最优值。针对复杂调度问题难以求解的难题, 本文将尝试改进标准 GWO 算法, 进一步提高其求解复杂调度问题的优化性能。




图2 FT06和LA01测试实例甘特图

3.3 IGWO 和 GWO 算法的比较

本文在标准 GWO 算法的基础上,加入了进化种群动态、反向学习初始化种群,以及最优个体变异三个方面的改进操作,改进后的算法命名为 IGWO。针对表 1 中较难求解的七个测试实例,将改进后的算法与标准 GWO 算法进行比较研究,测试结果如表 2 所示。除了 IGWO 中灰狼种群个数设为 50,其余参数设置同上保持不变。从表 2 的测试数据结果可以看出,虽然改进后的算法仍然不能找到问题的已知最优值,但是

相较于标准 GWO 算法,IGWO 算法的优化性能已经有了一定的改善,从最小值提升率和平均值提升率两个指标可以看出;另外,从 Δ_{std} 指标可以看出 IGWO 算法的求解结果稳定性更好。本文选取了两个较复杂的测试实例 FT20 和 LA26,分别画出了它们的寻优曲线对照图,如图 4 所示。迭代曲线表明所提出的 IGWO 算法能够跳出局部最优值,找到更好的解,同时由于融入了 CS 算法的某些特性,结果鲁棒性更强。

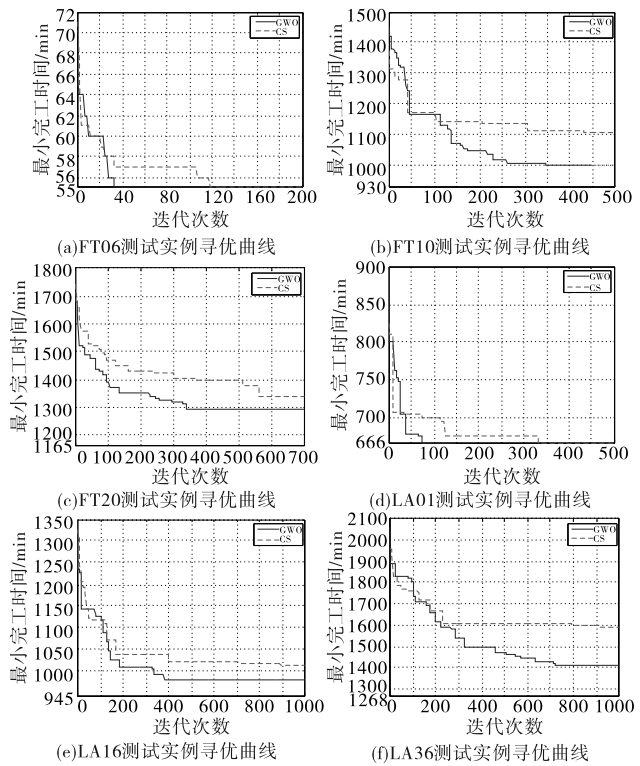


图3 GWO和CS算法寻优曲线对照图

表 1 GWO 和 CS 算法测试结果对比

实例名称	问题规模	c^*	GWO					CS				
			Δ_{min}	Δ_{max}	Δ_{avg}	Δ_{std}	寻优成功率/%	Δ_{min}	Δ_{max}	Δ_{avg}	Δ_{std}	寻优成功率/%
FT06	6 × 6	55	55	59	57.6	1.5	20	55	56	55.03	0.18	96.7
FT10	10 × 10	930	989	1 179	1 061.8	42.4	0	1 075	1 174	1 131.6	26.6	0
FT20	20 × 5	1 165	1 274	1 495	1 378.4	46.7	0	1 368	1 484	1 429.2	30.3	0
LA01	10 × 5	666	666	720	673.7	12.2	56.7	666	680	667.03	3.3	86.7
LA06	15 × 5	926	926	943	926.6	3.1	96.7	926	926	926	0	100
LA11	20 × 5	1 222	1 222	1 224	1 222.1	0.4	93.3	1 222	1 243	1 226.8	7.3	56.7
LA16	10 × 10	945	979	1 077	1 026.4	27.9	0	1 015	1 075	1 043.8	13.6	0
LA21	15 × 10	1 046	1 167	1 410	1 235.3	48.6	0	1 267	1 382	1 331.5	25.7	0
LA26	20 × 10	1 218	1 345	1 680	1 459.3	81.5	0	1 487	1 662	1 614.6	29.9	0
LA31	30 × 10	1 784	1 871	2 167	1 979.8	55.6	0	2 102	2 246	2 198.8	32.5	0
LA36	15 × 15	1 268	1 393	1 824	1 501.7	79.2	0	1 600	1 703	1 655	25.5	0

注: c^* 为已知的最小化最大完工时间的最优值; Δ_{min} 为算法运行 30 次得到的最小化最大完工时间的最小值; Δ_{max} 为最大值; Δ_{avg} 为均值; Δ_{std} 为方差;加粗的数字表示搜索到已知最优值

表 2 GWO 和 IGWO 算法测试结果对比

实例名称	问题规模	c^*	GWO				IGWO				最小值提升率	平均值提升率
			Δ_{min}	Δ_{max}	Δ_{avg}	Δ_{std}	Δ_{min}	Δ_{max}	Δ_{avg}	Δ_{std}	/%	/%
FT10	10 × 10	930	989	1 179	1 061.8	42.4	982	1 120	1 044.7	32.0	0.71	1.61
FT20	20 × 5	1 165	1 274	1 495	1 378.4	46.7	1 223	1 390	1 312.6	40.2	4.00	4.77
LA16	10 × 10	945	979	1 077	1 026.4	27.9	958	1 077	1 011.5	24.2	2.15	1.45
LA21	15 × 10	1 046	1 167	1 410	1 235.3	48.6	1 144	1 279	1 207.6	34.4	1.97	2.24
LA26	20 × 10	1 218	1 345	1 680	1 459.3	81.5	1 312	1 491	1 411.6	44.5	2.45	3.27
LA31	30 × 10	1 784	1 871	2 167	1 979.8	55.6	1 860	2 153	1 950.2	62.7	0.59	1.50
LA36	15 × 15	1 268	1 393	1 824	1 501.7	79.2	1 369	1 542	1 459.4	42.4	1.72	2.82

注:各个符号代表的含义同表 1




图4 IGWO、GWO和CS算法寻优曲线对照图

4 结束语

灰狼优化算法是当前比较新颖的一种元启发式优化算法,目前多用于连续函数问题的优化研究,在作业车间调度这类比较复杂的离散组合优化问题方面的研究应用还比较少。

本文首先验证了标准 GWO 算法求解经典作业车间调度问题的可行性和有效性。在此基础上,针对复杂作业车间调度问题难以求解的特点,对标准 GWO 算法进行改进,通过进化种群动态、反向学习初始化种群,以及最优个体变异三个方面的改进操作,仿真结果表明改进后的混合灰狼优化算法能够有效跳出局部最优值,找到更好的解,且结果鲁棒性更强。

未来将进一步探索使用多目标灰狼优化算法解决更加复杂的生产调度问题。

参考文献:

- [1] 王永明,尹红丽,秦开大. 作业车间调度理论及其优化方法研究[M]. 北京:科学出版社,2013:1-25.
- [2] Mirjalili S, Mirjalili S M, Lewis A. Grey wolf optimizer[J]. *Advances in Engineering Software*, 2014, 69(3): 46-61.
- [3] Saremi S, Mirjalili S Z, Mirjalili S M. Evolutionary population dynamics and grey wolf optimizer[J]. *Neural Computing and Applications*, 2015, 26(5): 1257-1263.
- [4] Mirjalili S, Saremi S, Mirjalili S M, et al. Multi-objective grey wolf optimizer: a novel algorithm for multi-criterion optimization[J]. *Expert Systems with Applications*, 2016, 47(4): 106-119.

- [5] Lu Chao, Xiao Shengqiang, Li Xinyu, et al. An effective multi-objective discrete grey wolf optimizer for a real-world scheduling problem in welding production[J]. *Advances in Engineering Software*, 2016, 99(9): 161-176.
- [6] Lu Chao, Gao Liang, Li Xinyu, et al. A hybrid multi-objective grey wolf optimizer for dynamic scheduling in a real-world welding industry[J]. *Engineering Applications of Artificial Intelligence*, 2017, 57(1): 61-79.
- [7] 吕新桥,廖天龙. 基于灰狼优化算法的置换流水线车间调度[J]. *武汉理工大学学报*, 2015, 37(5): 111-116.
- [8] 陈昌帅. 二进制灰狼优化算法的研究与分析[J]. *信息系统工程*, 2016(7): 136-138.
- [9] 王凌. 智能优化算法及其应用[M]. 北京:清华大学出版社, 2001: 10-16.
- [10] 罗亚波. 作业系统调度优化理论与方法[M]. 武汉:华中科技大学出版社, 2011: 1-10.
- [11] Yang Xinshe. Nature-inspired metaheuristic algorithms[M]. 2nd ed. Frome: Luniver Press, 2010: 16.
- [12] Tizhoosh H R. Opposition-based learning: a new scheme for machine intelligence[C]//Proc of International Conference on Computational Intelligence for Modelling Control and Automation. [S. l.]: IEEE Press, 2005: 695-701.
- [13] Wang Yong, Cai Zixing, Zhou Yuren, et al. Constrained optimization based on hybrid evolutionary algorithm and adaptive constraint-handling technique[J]. *Structural and Multidisciplinary Optimization*, 2009, 37(4): 395-413.
- [14] 陈乐, 龙文. 求解工程结构优化问题的改进布谷鸟搜索算法[J]. *计算机应用研究*, 2014, 31(3): 679-683.
- [15] Yang Xinshe, Deb S. Cuckoo search via Lévy flights[C]//Proc of World Congress on Nature & Biologically Inspired Computing. New York: IEEE Publications, 2009: 210-214.
- [16] Yang Xinshe, Deb S. Engineering optimisation by cuckoo search[J]. *International Journal of Mathematical Modelling and Numerical Optimisation*, 2010, 1(4): 330-343.

(上接第1297页)

- [7] 王筱莉,赵来军,谢婉林. 无标度网络中遗忘率变化的谣言传播模型研究[J]. *系统工程理论与实践*, 2015, 35(2): 458-465.
- [8] Clara G, Sergio G, Alex A. Dynamical interplay between awareness and epidemic spreading in multiplex networks[J]. *Physical Review Letters*, 2013, 111(12): 128701.
- [9] Clara G, Sergio G, Alex A. Competing spreading processes on multiplex networks: awareness and epidemics[J]. *Physical Review E: Statistical Nonlinear & Soft Matter Physics*, 2014, 90(1): 012808.
- [10] Perra N, Gonçalves B, Pastorsatorras R, et al. Activity driven modeling of time varying networks[J/OL]. *Scientific Reports*, (2012) [2017-01-03]. <http://dx.doi.org/10.1038/srep00469>.
- [11] 毕贵红,何晓力,王海瑞. IDU 大规模社会网络及其 HIV 传播模拟[J]. *系统管理学报*, 2016, 25(2): 353-363.
- [12] Huo Liang'an, Huang Peiqing, Fang Xing. An interplay model for authorities' actions and rumor spreading in emergency event[J]. *Physica A: Statistical Mechanics and Its Applications*, 2011, 390(20): 3267-3274.
- [13] 郭强,刘新惠,胡兆龙. 真实信息发布在谣言传播中的作用研究[J]. *计算机应用研究*, 2014, 31(4): 1031-1034, 1050.
- [14] 樊重俊,李佳婷,霍良安,等. 谣言传播过程中官方媒体影响模型[J]. *计算机应用研究*, 2016, 33(11): 3364-3368.

- [15] 王辉,韩江洪,邓林,等. 基于移动社交网络的谣言传播动力学研究[J]. *物理学报*, 2013, 62(11): 110505.
- [16] 强韶华,吴鹏. 谣言信息传播过程中网民个体行为仿真研究[J]. *情报科学*, 2015, 33(11): 124-130.
- [17] Han Shuo, Zhuang Fuzhen, He Qing, et al. Energy model for rumor propagation on social networks[J]. *Physica A: Statistical Mechanics and Its Applications*, 2014, 394(1): 99-109.
- [18] 王亚奇,王静,杨海滨. 基于复杂网络理论的微博用户关系网络演化模型研究[J]. *物理学报*, 2014, 63(20): 208902.
- [19] 宋之杰,王建,石蕊. 基于无标度网络的突发事件微博谣言传播研究[J]. *情报杂志*, 2015(12): 111-115.
- [20] 万贻平,张东戈,任清辉. 考虑谣言清除过程的网络谣言传播与抑制[J]. *物理学报*, 2015, 64(24): 240501.
- [21] Rizzo A, Frasca M, Porfiri M. Effect of individual behavior on epidemic spreading in activity-driven networks[J]. *Physical Review E*, 2014, 90(4): 246-266.
- [22] Granell C, Gómez S, Arenas A. Competing spreading processes on multiplex networks: awareness and epidemics[J]. *Physical Review E*, 2014, 90(1): 012808.
- [23] Barabási A L, Albert R, Jeong H. Mean-field theory for scale free random networks[J]. *Physica A: Statistical Mechanics & Its Applications*, 1999, 272(1): 173-187.
- [24] Sanz J, Meloni S, Moreno Y, et al. Dynamics of interacting diseases[J]. *Physical Review X*, 2014, 4(4): 041005.