

基于独立成分分析功能连接的抑郁症分类研究*

茂旭^{1a,2,3}, 杨剑^{1a,2,3}, 杨阳^{1b}

(1. 北京工业大学 a. 信息学部; b. 北京未来网络科技高精尖创新中心, 北京 100124; 2. 磁共振成像脑信息学北京市重点实验室, 北京 100124; 3. 脑信息智慧服务北京市国际科技合作基地, 北京 100124)

摘要: 已有的功能连接研究大多根据脑图谱构建全脑功能连接,但目前可选用的脑图谱种类有限,且采用不同脑图谱的分析结果可能存在一定的差异。针对上述问题,利用独立成分分析方法研究了抑郁症辅助诊断问题。首先利用组独立成分分析提取独立成分并构建全脑功能连接网络,然后采用 BoostFS (boosting feature selection) 方法进行特征选择,最后应用多元模式分析方法对 20 名抑郁症患者和 21 名健康被试进行分类。实验分类准确率达到 95.12%,错分了一名抑郁症患者和一名健康被试。进一步分析表明,具有较强分辨能力的脑网络为感觉运动网络、默认网络和视觉网络,与已有基于脑图谱的研究结果基本一致,从而说明了基于独立成分分析方法的合理性,使其可能成为抑郁症辅助诊断的一种新方法。

关键词: 功能磁共振成像; 抑郁症; 全脑功能连接; 独立成分分析

中图分类号: TP391.4

文献标志码: A

文章编号: 1001-3695(2018)06-1641-04

doi:10.3969/j.issn.1001-3695.2018.06.009

Independent component analysis based functional connectivity for classification of depression

Mao Xu^{1a,2,3}, Yang Jian^{1a,2,3}, Yang Yang^{1b}

(1. a. Faculty of Information Technology, b. Beijing Future Network Technology High-Tech Innovation Center, Beijing University of Technology, Beijing 100124, China; 2. Beijing Key Laboratory of Magnetic Resonance Imaging & Brain Informatics, Beijing 100124, China; 3. Beijing International Collaboration Base on Brain Informatics & Wisdom Services, Beijing 100124, China)

Abstract: Previous functional connectivity studies usually utilize brain atlas to construct whole-brain functional connectivity network. However, available brain atlas is limited and the results using different brain atlas might be different. In order to overcome the problems above, this paper investigated the computer aided diagnosis of depression using independent component analysis method. Firstly, it extracted independent components to construct whole-brain functional connectivity network, and then used BoostFS method for feature selection. Finally, it employed multivariate pattern analysis method to classify 20 depressed patients and 21 healthy controls. The classification accuracy of the proposed method was up to 95.12% (only one healthy control subject and one depressed patient were classified incorrectly). Further analysis demonstrates that the most discriminative brain networks are sensorimotor network, default mode network and visual network, which is consistent with the existing results of brain atlas. This indicates that the proposed independent component analysis based method is reasonable, and it might be a new method for the diagnosis of depression.

Key words: functional magnetic resonance imaging; depression; whole-brain functional connectivity; independent component analysis

0 引言

抑郁症是一种常见的精神障碍疾病,以显著而持久的情绪低落为主要临床特征,严重者可能出现自杀念头和行为,给家庭和社会造成极大负担。目前,抑郁症的诊断主要依据量表和医生的经验,这种诊断方式具有一定的主观性,诊断准确率偏低、误诊率偏高。而基于功能磁共振成像(functional magnetic resonance imaging, fMRI)等脑成像数据对精神疾病进行辅助诊断能在一定程度上避免人为主观因素的影响,受到了研究者的高度关注^[1,2]。

利用 fMRI 技术,从脑功能角度研究抑郁症的发病机理得

到了广泛关注^[3-5]。基于静息态(被试保持清醒、不执行特定认知任务的状态)fMRI 的抑郁症脑功能连接研究已经取得了很多重要的成果。研究发现,抑郁症患者部分脑区之间的功能连接明显异于健康人,如前扣带回皮层与边缘系统及丘脑区域的功能连接减弱^[3]、眶额叶皮层与楔前叶之间的功能连接减弱^[4]、亚属扣带皮层与丘脑之间的功能连接增强^[5]等。研究还发现,抑郁症患者的某些特定脑网络存在异常,如默认网络和情感网络^[6,7]。这些基于单变量统计的组分析结果不仅揭示了抑郁症患者的脑功能异常,也为构建基于脑功能连接的抑郁症辅助诊断方法提供了理论依据。

近年来有研究者开始借助抑郁症患者与健康人之间的功能连接差异,采用多元模式分析(multivariate pattern analysis,

收稿日期: 2017-01-16; 修回日期: 2017-03-02 基金项目: 国家“973”计划资助项目(2014CB744600); 国家自然科学基金资助项目(61420106005); 北京市自然科学基金资助项目(4164080)

作者简介: 茂旭(1992-),男,北京人,硕士研究生,主要研究方向为模式识别、数据挖掘(maoxu99@emails.bjut.edu.cn); 杨剑(1976-),男,四川简阳人,副教授,博士,主要研究方向为模式识别、数据挖掘; 杨阳(1984-),男,云南曲靖人,博士,主要研究方向为脑信息学、认知神经心理学。

MVPA)方法进行抑郁症的辅助诊断研究^[2,8]。基于功能连接的研究可以分为基于感兴趣区域(region of interest, ROI)的功能连接以及基于全脑的功能连接两类。不同于只分析事先选定 ROI 的功能连接研究,全脑功能连接分析可以对脑影像数据提供的丰富信息进行最大化的利用,并且可以用于分析大规模的脑功能连接网络,因而得到了越来越多研究者的青睐^[8,9]。定义网络节点是全脑功能连接分析中非常关键的步骤。在已有的研究中,大部分研究者都是将脑图谱模板划分的脑区定义为功能连接网络的节点。然而这种节点的定义方法依赖于先验的脑图谱模板,使得采用不同脑图谱模板建立的全脑功能连接网络存在着先天的差异,从而影响功能连接网络的分析结果^[9,10]。而独立成分分析(independent component analysis, ICA)是一种数据驱动的多元分析方法,无须先验知识即可分离出 fMRI 信号中相互独立的信号源^[11]。相比于脑图谱模板的方法,ICA 能更加充分地利用体素间的空间联系,得到更加合理的功能连接模式。因此,本文采用组独立成分分析提取大脑 fMRI 数据中的独立成分(independent component, IC),以分离出的独立成分作为节点构建全脑功能连接网络,避免应用不同脑图谱模板造成的分析结果差异。

本文采用基于 ICA 的全脑功能连接分析方法研究抑郁症的辅助诊断问题,主要包括以下三个步骤:a)利用组独立成分分析提取静息态 fMRI 数据中的独立成分,选取能够代表自发神经活动的独立成分作为节点构建全脑功能连接网络;b)以全脑功能连接为特征,采用肯德尔排序相关系数法^[8]和笔者提出的 BoostFS(boosting feature selection)两种特征选择方法分别进行特征选择;c)采用多元模式分析方法对抑郁症患者和健康被试进行分类。在对 20 名抑郁症患者和 21 名健康被试进行分类时,本文提出的方法分类准确率可达 95.12%。进一步的分析表明,在分类抑郁症患者和健康被试的问题中,具有较强分辨能力的脑网络为感觉运动网络、默认网络和视觉网络,从而验证了与抑郁症相关的脑网络异常。

1 被试与 fMRI 数据

1.1 被试

本研究共征集到 41 名被试,包括来自首都医科大学附属北京安定医院门诊的 20 名抑郁症患者(8 名男性,12 名女性,平均年龄 35.25 ± 9.54 岁)和广告招募的 21 名健康对照(8 名男性,13 名女性,平均年龄 34.19 ± 9.01 岁),全部被试均为右利手。本研究中的抑郁症患者都符合美国精神障碍诊断与统计学手册(DSM-IV)和 17 项汉密尔顿顿量表(HAMD)的抑郁症诊断标准。排除标准包括严重的身体疾病、药物滥用史、导致意识丧失的头部损伤病史和除抑郁症之外的严重精神或神经疾病,类似的排除标准也适用于健康被试。本研究获得了当地伦理委员会的批准,所有被试均签署了实验知情同意书。

1.2 fMRI 数据的采集与预处理

fMRI 数据采用德国西门子 3.0T 磁共振扫描仪,12 通道相控头部线圈进行采集。在扫描过程中,被试头部采用海绵垫固定以防止产生头动位移,同时要求被试闭眼、放松、身体静止不动、尽量不作任何思考。采用平面回波成像(echo planar imaging, EPI)序列扫描,扫描参数如下:重复时间/回波时间 = 2000/31 ms、层厚/间隔 = 4/0.8 mm、矩阵 = 64×64 、视野范围 = $240 \text{ mm} \times 240 \text{ mm}$ 、层数 = 20。扫描时间为 310 s,对应 152 个时间点。由于磁场饱和以及被试适应扫描环境,去除每个被试前 10 个时间点数据。其余预处理步骤包括:a)时间校正,校

正图像在获取时间上的差异;b)头动校正,减少头动对所采集数据的影响,如果超过允许的头动范围就剔除这个被试的所有数据,剔除标准为头部平动 $> 3 \text{ mm}$ 或转动 $> 3^\circ$;c)空间标准化,将所有头动校正后的图像标准化到 MNI(montreal neurological institute)空间的 EPI 模板上,并重采样每个体素为 3 mm 的立方体,以克服不同被试的脑结构之间的差异;d)空间平滑,为减少标准化后剩余的个体间差异,提高信噪比,对空间标准化得到的图像进行 10 mm 半高全宽高斯空间平滑。

2 基于 ICA 全脑功能连接的抑郁症分类

对预处理后的 fMRI 数据,通过组独立成分分析方法提取数据中的空间独立成分,去除明显的噪声成分之后,将剩下的独立成分作为节点构建全脑功能连接网络,以功能连接作为特征,采用多元模式分析方法对抑郁症患者与健康被试进行分类判别。具体流程如图 1 所示。

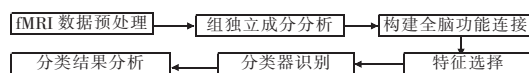


图 1 基于 ICA 全脑功能连接的分类流程

2.1 组独立成分分析

独立成分分析(ICA)是一种多元数据驱动的分析方法,不需要模型驱动方法中预先假设的先验模型,这对于 fMRI 数据的分析研究具有很大的优势,因此已成为分析和处理 fMRI 数据的重要方法之一。fMRI 数据处理中应用的 ICA 方法可分为时间 ICA 和空间 ICA 两种。由于 fMRI 数据空间维数远大于时间维数,所以空间 ICA 算法占主流。空间 ICA 假设源信号之间是空间相互独立且是非高斯分布的,将数据分解为一系列独立的空间成分(各种与噪声等相对应的成分和各个脑网络)以及相对应的时间序列。这种假设对于脑功能活动是合理的,并且能够分离出比较合理的功能模式^[12]。在 fMRI 数据分析中常常需要寻找不同被试间具有一致性的模式。然而由于被试间的个体差异,不同被试所得出来的独立成分是有差别的,并不能将每个被试单独进行 ICA 后获得的独立成分进行简单联合分析^[12]。组独立成分分析将所有被试的 fMRI 数据连接在一起进行 ICA 估计,寻找在各个被试之间较为一致的公共成分,其获得的脑区活动结果具备统计学意义,并且可用于组间统计推断。因此,本文采用组独立成分分析对 fMRI 数据进行空间分解。图 2 是组独立成分分析的主要步骤。




图 2 组独立成分分析流程

对 fMRI 数据降维之后,本文采用信息极大化(Infomax)算法进行独立成分的估计和分离。该算法的出发点是通过最大化输入和输出的互信息等价地达到输出各分量间互信息的最小化。根据以往的研究经验^[13],设定 fMRI 信号中独立成分个数为 70。为了估计独立成分的可靠性,采用 Bootstrap 和不同初始值的方法多次运行 Infomax 算法,使用 ICASSO 软件估计独立成分的可靠性^[14]。使用组独立成分分析提取的独立成分既包括本文感兴趣的脑网络成分,也包括其他噪声信号。本文对组独立成分的空间分布和功率谱进行人工视觉检查以剔除噪声成分。脑网络成分的选择标准为:主要激活分布于灰质区域且与已知的血管、头动等成分低空间重叠;时间序列的功率谱以低频功率为主。根据视觉观察,本文去除了 31 个含噪声较多的成分后保留了 39 个脑网络成分。通过空间匹配的方法选择与典型脑网络成分^[12]最匹配的独立成分,最终确定这些独立成分分别为感觉运动网络、默认网络、视觉网络、听觉网

络、注意网络和额叶网络。

2.2 构建全脑功能连接网络

在计算全脑功能连接之前,需要对每个被试独立成分的时间序列进行后处理,以去除线性漂移和高频生理噪声的影响。具体包括:a)去除时间序列的线性、二次、三次趋势;b)多元线性回归头动参数;c)对时间序列异常值进行三阶样条插值;d)低通滤波(截止频率 0.15 Hz)。本文以去除噪声成分后剩下的 39 个独立成分所对应的大脑皮层位置作为全脑功能连接网络中的节点,以节点之间的功能连接(节点时间序列之间的 Pearson 相关系数)作为连接边构建全脑功能连接网络。对于每个被试,本文得到 39×39 的全脑功能连接矩阵,提取矩阵上三角元素作为分类特征(移除对角线元素),最终得到每个被试 741 维的特征向量。Pearson 相关系数的计算公式为

$$r_{i,j} = \frac{\text{cov}(i,j)}{\sigma_i \sigma_j} \quad (1)$$

其中: $r_{i,j}$ 表示独立成分 i 与 j 时间序列的 Pearson 相关系数; $\text{cov}(i,j)$ 表示两个独立成分时间序列的协方差; σ_i 和 σ_j 分别表示两个独立成分时间序列的标准差。

2.3 特征选择

对于分类问题来讲,去掉冗余的特征不仅可以加快计算速度,而且可以抑制噪声影响,改善分类性能。因此,在分类器设计之前常常要进行特征选择。本文采用两种方法进行特征选择,一种是肯德尔排序相关系数法(Kendall tau rank correlation coefficient),另一种是本文提出的 BoostFS 算法。

一个特征的判别能力可以通过它与类别标签的相关性来度量。肯德尔排序相关系数法可以在无分布假设的基础上检验样本与类别标签之间的相关性。假设抑郁组样本数量为 m ,对照组样本数量为 n , X_{ij} 代表第 j 个样本的第 i 个特征, Y_j 代表第 j 个样本的类别标签(患者标记为 +1,健康被试标记为 -1)。针对任意两个不同类别标签样本之间的 X_{ij} 与 Y_j 差异,若符号方向相同则为调和,符号方向不同则为非调和,那么第 i 个特征的肯德尔相关系数可以进行如下定义:

$$\tau_i = \frac{n_c - n_d}{m \times n} \quad (2)$$

其中: n_c 代表调和对数; n_d 代表非调和对数;样本总对数为 $m \times n$ 。因此,当 τ_i 为正时,表明与对照组相比,抑郁组的第 i 个特征减弱;当 τ_i 为负时,表明与对照组相比,抑郁组的第 i 个特征增强。 $|\tau_i|$ 越大,表明抑郁组和正常组在第 i 个特征上的差异越大,第 i 个特征的分类能力也就越强。对 $|\tau_i|$ 进行降序排序,选取排在最前面一定数目的特征作为分类测试样本的特征。

基于 Boosting 的特征选择最早出现在人脸检测领域^[15],展示了 Boosting 作为一种元算法框架在特征选择问题中的潜力。决策树桩(decision stump,DS)是仅有一个节点的决策树。一个训练好的 DS 相当于一个筛选出的特征,并且与其他特征相比,这个特征在仅用单一特征分类训练样本的情况下是最优的。以 DS 作为弱分类器的 AdaBoost 算法可以直接用于特征选择。具体地,在每一轮的弱分类器训练中,AdaBoost 算法从全部特征集中选出一个能使训练权重错误率最低的特征,并根据当前弱分类器的分类结果增大错分样本的权值,降低正确分类样本的权值,使那些没有被正确分类的样本由于权值加大而受到后一轮弱分类器的更大关注。每轮迭代 AdaBoost 算法会选择训练权重错误率最低的分类器作为本轮的弱分类器,同时也选择了本轮迭代中最具分辨能力的特征。当终止迭代时,某一特征出现的次数越多,证明在此特征上两类样本的分类间隔越大,此特征分辨能力也就越强。然后将特征按照它们的分

辨能力进行降序排序,选取排在最前面一定数目的特征作为分类测试样本的特征子集。BoostFS 算法伪代码如下所示。

BoostFS 特征选择算法

输入:训练集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$, 迭代次数 T , 特征维数 n 。

输出:选择的特征集合 $SF = \{s_1, s_2, \dots, s_T\}$ 。

初始化样本权重为 $1/2m, 1/2l$, 其中 m, l 是两类被试的样本数目

for $j = 1$ to T do

for $i = 1$ to n do

根据样本权重训练模型 $h_{i,j}$;

计算模型的 $h_{i,j}$ 错误率 $\text{error}(h_{i,j})$;

end

选出最小权重错误率的模型作为 h_j ;

将 h_j 所对应的特征作为 s_j 放入集合 SF ;

for 每个被正确分类的样本 do

样本的权重乘以 $\text{error}(h_{i,j}) / (1 - \text{error}(h_{i,j}))$

end

规范化每个样本的权重;

end

根据每个特征出现的次数对 SF 进行降序排序;

返回特征集合 SF ;

2.4 分类器设计与性能评估

支持向量机(support vector machine, SVM)在高维小样本问题上具有良好的分类能力,已经被广泛地用于神经影像数据中。SVM 的分类过程分为训练和测试两个阶段。在训练阶段, SVM 找到一个用于区分训练样本的最优决策面。一旦确定这个决策面,它将用于预测新样本的标签。为降低过拟合的风险,并且能够直接提取分类特征的权重,本文采用线性 SVM 分类器对抑郁患者和健康被试进行分类识别。分类器参数取默认值。由于样本数目有限,本文在分类过程中采用留一交叉验证法(leave-one-out cross validation, LOOCV)评价分类器的性能。分类器的性能可以量化为灵敏度(sensitivity, SEN)、特异度(specificity, SPE)和准确率(accuracy, ACC)。其计算公式为

$$\text{SEN} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{SPE} = \frac{TN}{TN + FP} \quad (4)$$

$$\text{ACC} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

其中: TP 是真阳性个数,即正确识别患者的个数; TN 是真阴性个数,即正确识别健康被试的个数; FP 是假阳性个数,即健康被试被错分的个数; FN 是假阴性个数,即患者被错分的个数。

为了确保所得到的分类准确率具有统计的显著性,将对最高分类准确率进行置换检验(permutation test),使用该方法将估计分类器和预测正确率在零假设(分类器不能可靠地学习数据和类别标签的关联)下的经验累积分布。在置换检验中,训练集的类别标签在分类器训练之前进行随机置换,交叉验证将在已置换标签的训练集上进行。标签被随机置换 10 000 次后所得 p 值((随机置换正确率 > 最高正确率的次数 + 1) / 10001),就是接受零假设的概率大小。

3 实验结果及分析

3.1 分类结果

对基于 ICA 的全脑功能连接特征,本文分别采用肯德尔排序相关系数法和 BoostFS 算法进行特征选择,并应用线性 SVM 分类器进行分类。具体结果如图 3 所示。从图 3 可以看

出,对于肯德尔排序相关系数法,当特征维数为 10 时,线性 SVM 分类器达到最高分类准确率(82.93%, $p < 0.0001$);而对于本文提出的 BoostFS 算法,当特征维数为 8 时,线性 SVM 分类器达到最高分类准确率(95.12%, $p < 0.0001$)。表 1 为图 3 所示的最优分类结果的性能及相应参数取值。




图3 肯德尔排序相关系数法和 BoostFS 算法得到的分类结果

表1 采用肯德尔相关系数法和 BoostFS 算法的最优分类结果及相应参数取值

特征选择算法	特征数	迭代次数	灵敏度/%	特异度/%	准确率/%
Kendall	10	-	85.0	80.95	82.93
BoostFS	8	150	95.0	95.24	95.12

从表1可以看出,肯德尔排序相关系数法和 BoostFS 算法都可以很好地找到与分类相关的特征,获得较高的分类准确率;但与肯德尔排序相关系数法相比,本文提出的 BoostFS 算法在灵敏度、特异度和准确率上均显示出优越性。

3.2 迭代次数对分类结果的影响

在使用 BoostFS 算法进行特征选择时,需要确定迭代次数 T ,其取值可能影响特征选择的性能,从而对分类结果产生影响。本文在不改变 BoostFS 算法和线性 SVM 分类器其他结构的前提下,测试弱分类器的个数即迭代次数 T 对分类结果的影响,实验结果如图4所示。从图4可以看出,迭代次数 T 对分类结果的影响较小,最优的迭代次数 T 为 150。




图4 不同迭代次数下的分类准确率

3.3 结果讨论

在分类过程中采用留一交叉验证法评价分类器的性能,而在每次交叉验证中的训练样本集是有细微差异的,这必将导致每次通过特征排序最终选择的特征集不同。因此,不同脑网络对分类的贡献是非均匀的,有些脑网络可能会与其他脑网络构成具有高分辨能力的功能连接,而另外一些可能不会构成具有高分辨能力的连接。为了衡量不同的脑网络对分类的相对贡献,在交叉验证过程中,每次分类后都将记录所选功能连接特征用于 SVM 分类得到的权重 w ,并对 $\|w\|^2$ 进行归一化,作为该特征在本次分类过程中的权重。当交叉验证结束时,统计所有参与分类的功能连接特征的平均权重,取其一半作为该功能连接特征所连接的脑网络的分类权重。特别地,如果某些脑网络的权重大于所有成分的平均权重加一倍的标准差,就认为这些脑网络具有显著高的权重。在表2给出 BoostFS 算法的最高分类准确率下,整个留一交叉验证过程中共出现了 28 个功能连接特征,涉及 30 个脑网络成分。图5给出了分类权重最大的前 10 个脑网络成分,前 4 个成分为具有显著高分类权重的脑网络成分,依次为感觉运动网络、默认网络、感觉运动网络和视觉网络。




图5 分类权重最大的 10 个脑网络成分

从图5可以得出以下结论:

a) 感觉运动网络具有最大的分类权重,表明它在分类抑郁患者和健康被试过程中起到较大的作用。感觉运动网络主要分布在中央前回、中央后回、中央旁小叶和辅助运动区等区域,主要参与低级认知的加工和处理^[16]。感觉运动网络的功能异常可能与抑郁病人感觉功能的受损密切相关。

b) 默认网络和视觉网络同样表现出较大的分类权重。默认网络可以被看做是一个高级的认知网络系统,其主要功能自我参照,而这种功能已经被证实了在抑郁症患者中受损^[6],因此本文的发现也支持了默认网络在抑郁症中起重要作用的观点。视觉网络主要分布在视觉皮层区域(包括舌状回、梭状回、枕下回和距状回)。异常的视觉网络可能与抑郁患者选择性注意和工作记忆失常有关^[17]。这些结果与以往基于脑图谱的全脑功能连接的研究结果^[6-8]基本一致。但是采用基于 ICA 的全脑功能连接分析具有以下两个优点:a) ICA 是一种数据驱动的方法,基于 ICA 进行全脑功能连接研究能够避免应用不同脑图谱模板造成的分析结果差异,所得结果更具有可靠性;b) 大脑是作为一个整体进行协同工作而非仅仅依赖于个别大脑功能区域的活动,因此从脑网络角度来研究抑郁患者大脑的组织特性有助于进一步理解抑郁症的发病机制和相关临床表现。

4 结束语

以往的研究揭示出抑郁症患者与健康对照之间存在差异性的功能连接^[3-7]。本文基于独立成分分析构建了抑郁症患者和健康对照组的全脑功能连接网络,采用多元模式分析方法对抑郁症患者和健康被试进行分类。实验结果表明,本文方法具有较高的准确率,为抑郁症的辅助诊断提供了一种可能有效的解决方案。但本文的研究仍有很多不足之处,如研究结果需独立大样本验证、目前对于成分数目的估计有不同的观点、需尝试不同的独立成分数目等。本文对于功能连接的计算是基于其在整个数据采集周期内稳定不变的假设下,而近期的研究表明静息态功能连接网络随着时间变化存在一定的波动性。因此,今后的研究可以从动态功能连接角度研究抑郁症患者和健康被试大脑功能网络的异常。

参考文献:

- [1] Wise T, Cleare A J, Herane A, et al. Diagnostic and therapeutic utility of neuroimaging in depression: an overview [J]. *Neuropsychiatric Disease & Treatment*, 2014, 10(8): 1509-1522.
- [2] Craddock R C, Holtzheimer P E, Hu Xiaoping, et al. Disease state prediction from resting state functional connectivity [J]. *Magnetic Resonance in Medicine*, 2009, 62(6): 1619-1628.
- [3] Anand A, Li Yu, Wang Yang, et al. Resting state corticolimbic connectivity abnormalities in unmedicated bipolar disorder and unipolar depression [J]. *Psychiatry Research*, 2009, 171(3): 189-198.

(下转第 1699 页)

为识别方法准确率较与选取纯粹的时、频域特征集进行识别分类的模型准确率大幅提高,对人体走路、站立、跑步、上楼、下楼共五种常见人体行为准确率平均达到92%。其中C4.5决策树的平均识别准确率达到94.4%,四种分类器对站立、跑步识别效果尤为显著,相比未使用自相关函数特征的分类模型识别准确率提高了9%。包含了新特征的四种分类器在上楼、下楼识别结果最差达到了87%,但是仍比采用未包含新特征的模型识别准确率高出6%。表6所示为使用自相关函数特征前后准确率对比。

表6 使用自相关函数特征前后准确率对比(前/后)

分类模型	站立	走路	跑步	上楼	下楼
朴素贝叶斯	0.88/0.96	0.79/0.87	0.89/0.93	0.85/0.89	0.86/0.87
C4.5 决策树	0.87/0.90	0.90/1.0	0.92/1.0	0.85/0.90	0.87/0.93
K 最近邻	0.87/0.94	0.85/0.87	0.86/0.89	0.88/0.92	0.86/0.91
支持向量机	0.85/0.89	0.89/0.95	0.90/0.94	0.84/0.92	0.84/0.92

3 结束语

本文提出了一种基于智能手机传感器的人体行为识别方法,用来提高人体行为识别的准确率。该方法采用Android智能手机传感器获取人体移动过程中的行为数据,经过预处理和自相关函数特征提取、采取互相关函数的步进式方法降噪后利用决策树、朴素贝叶斯、K最近邻、支持向量机分类算法建立行为模型。通过实验验证了将自相关函数特征加入特征集中有利于提高行为识别准确率,四种分类算法平均准确率达到92%。实验结果充分证明了该方法的有效性。

参考文献:

- [1] Ghose S, Mitra J. Human activity recognition from smart-phone sensor data using a multi-class ensemble learning in home monitoring [J]. *Studies in Health Technology & Informatics*, 2015, 214: 62.
- [2] 王昌喜, 杨先军, 徐强, 等. 基三维加速度传感器的上肢动作识别系统[J]. *传感器技术学报*, 2010, 23(6): 816-819.
- [3] Gupta P, Dallas T. Feature selection and activity recognition system using a single triaxial accelerometer [J]. *IEEE Trans on Engineering*, 2014, 61(6): 1780-1786.
- [4] 王泰青, 王生进, 丁晓青. 基于最大互信息区域跟踪的人体行为检测算法[J]. *自动化学报*, 2012, 38(12): 2023-2031.
- [5] 范琳, 王忠民. 穿戴位置无关的手机用户行为识别模型[J]. *计算机应用研究*, 2015, 32(1): 63-66.
- [6] Ustev Y E, Incel O D, Ersoy C. User, device and orientation independent human activity [C]//Proc of ACM Conference on Pervasive and Ubiquitous Computing Adjunct Publication. New York: ACM Press, 2013: 1427-1436.
- [7] 李月香, 刘燕, 袁涛, 等. 基于加速度信号的走路模式多级分类算法[J]. *电子学报*, 2009, 37(8): 1794-1798.
- [8] Incel O D, Kose M, Ersoy C. A review and taxonomy of activity recognition on mobile phones [J]. *BioNanoScience*, 2013, 3(2): 145-171.
- [9] Robertas D. Human activity recognition in AAL environments using random projections [J]. *Computational & Mathematical Methods in Medicine*, 2016, 2016(6): 1-17.
- [10] Ross R, Kelleher J. A comparative study of the effect of sensor noise on activity recognition models [C]//Proc of International Joint Conference on Ambient Intelligence. Cham, Switzerland: Springer International Publishing, 2013: 151-162.
- [11] Parviainen J, Bojja J, Collin J, et al. Adaptive activity and environment recognition for mobile phones [J]. *Sensors*, 2014, 14(11): 20753-20778.
- [12] Khan A M. Exploratory data analysis of acceleration signals to select light-weight and accurate features for real-time activity recognition on smartphones [J]. *Sensors*, 2013, 13(10): 13099-13122.
- [13] Kaffle S, Dou Dejing. A heterogeneous clustering approach for human activity recognition [C]//Proc of International Conference on Big Data Analytics and Knowledge Discovery. Cham, Switzerland: Springer International Publishing, 2016: 68-81.
- [4] Frodl T, Scheuerecker J, Albrecht J, et al. Neuronal correlates of emotional processing in patients with major depression [J]. *World Journal of Biological Psychiatry*, 2009, 10(3): 202-208.
- [5] Greicius M D, Flores B H, Menon V, et al. Resting-state functional connectivity in major depression: abnormally increased contributions from subgenual cingulate cortex and thalamus [J]. *Biological Psychiatry*, 2007, 62(5): 429-437.
- [6] Sheline Y I, Price J L, Yan Zhizi, et al. Resting-state functional MRI in depression unmasks increased connectivity between networks via the dorsal nexus [J]. *Proceedings of the National Academy of Sciences*, 2010, 107(24): 11020-11025.
- [7] Zhou Yuan, Yu Chunshui, Zheng Hua, et al. Increased neural resources recruitment in the intrinsic organization in major depression [J]. *Journal of Affective Disorders*, 2010, 121(3): 220-230.
- [8] Zeng Lingli, Shen Hui, Liu Li, et al. Identifying major depression using whole-brain functional connectivity: a multivariate pattern analysis [J]. *Brain*, 2012, 135(5): 1498-1507.
- [9] Wang Jinhui, Wang Liang, Zang Yufeng, et al. Parcellation-dependent small-world brain functional networks: a resting-state fMRI study [J]. *Human Brain Mapping*, 2009, 30(5): 1511-1523.
- [10] Zalesky A, Fornito A, Harding I H, et al. Whole-brain anatomical networks: does the choice of nodes matter? [J]. *NeuroImage*, 2010, 50(3): 970-983.
- [11] Calhoun V D, Adali T, Pearlson G D, et al. A method for making group inferences from functional MRI data using independent component analysis [J]. *Human Brain Mapping*, 2001, 14(3): 140-151.
- [12] McKeown M J, Sejnowski T J. Independent component analysis of fMRI data: examining the assumptions [J]. *Human Brain Mapping*, 1998, 6(5-6): 368-372.
- [13] Allen E A, Erhardt E B, Damaraju E, et al. A baseline for the multivariate comparison of resting-state networks [J]. *Frontiers in Systems Neuroscience*, 2011, 5(5): 2.
- [14] Himberg J, Hyvärinen A, Esposito F. Validating the independent components of neuroimaging time series via clustering and visualization [J]. *NeuroImage*, 2004, 22(3): 1214-1222.
- [15] Viola P, Jones M. Robust real-time face detection [J]. *International Journal of Computer Vision*, 2004, 57(2): 137-154.
- [16] Mantini D, Perrucci M G, Gratta C D, et al. Electrophysiological signatures of resting state networks in the human brain [J]. *Proceedings of the National Academy of Sciences*, 2007, 104(32): 13170-13175.
- [17] Deseilles M, Balteau E, Sterpenich V, et al. Abnormal neural filtering of irrelevant visual information in depression [J]. *Journal of Neuroscience*, 2009, 29(47): 1395-1403.

(上接第1644页)