

一种基于自相关函数特征的行为识别方法^{*}

王忠民, 李 杨[†], 张 荣
(西安邮电大学 计算机学院, 西安 710061)

摘要: 为了增强特征敏感度, 提高人体日常行为识别准确率, 针对行为识别特征进行了研究, 提出一种基于自相关函数特征的人体行为识别方法。首先对预先采集的人体行为数据进行预处理, 然后从时域和频域提取特征后计算得到自相关函数特征, 同时采取互相关函数的步进式方法在自相关函数上进行降噪操作。分别使用C4.5决策树、K最近邻、支持向量机、朴素贝叶斯四种分类器进行分类。实验结果表明, 与选取纯粹的时、频域特征集进行识别分类的模型相比, 选用了包含自相关函数特征的特征集构造出来的模型对行为的识别准确率有较大提高。

关键词: 行为识别; 自相关函数特征; 特征提取; 特征敏感度

中图分类号: TP391.4 **文献标志码:** A **文章编号:** 1001-3695(2018)06-1696-04

doi: 10.3969/j.issn.1001-3695.2018.06.021

Action recognition method based on features of autocorrelation function

Wang Zhongmin, Li Yang[†], Zhang Rong

(School of Computer Science & Technology, Xi'an University of Posts & Telecommunications, Xi'an 710061, China)

Abstract: In order to enhance feature sensitivity and improve recognition accuracy of human daily actions, this paper researched the features of activity recognition, and presented a human action recognition method based on the autocorrelation function features. The method preprocessed the pre-collected human action data firstly, and then calculated to obtain features of the autocorrelation function after extracting features from the time domain and the frequency domain, and at the same time, it performed noise reduction operations on the autocorrelation function by using a step-by-step method of the cross-correlation function. It separately performed classification by using four classifiers including C4.5 decision tree, K-nearest neighbor (KNN), support vector machine (SVM), and naive Bayesian. Experimental results show that, compared with the model recognized and classified by selecting pure time domain and frequency domain feature sets, the model constructed by using feature sets including the features of the autocorrelation function greatly improves actions recognition accuracy.

Key words: action recognition; features of autocorrelation function; feature extraction; feature sensitivity

0 引言

实时活动监测技术可以更智能地使人们保持健康的生活方式, 人体行为识别研究应用于老年人跌倒行为检测、智能家居等提高人们生活质量^[1]。

目前, 国内外研究者在行为识别方面做了以下研究并且取得了一定成果:

a) 利用智能手机、智能手表、智能手环等设备的内置传感器动态感知用户活动行为, 通过数据挖掘分类算法来进行对象感兴趣的移动模式识别。

例如, 文献[2]在人体脚踝处固定加速度传感器来研究人体行为识别、在手臂上固定相关传感器来解决人体上肢行为识别; 文献[3]利用和分析K最近邻(KNN)算法在分段时域特征优选进行人体行为识别。

b) 改进或者混合识别模型与识别算法来提高识别精度。文献[4]在随机森林轨迹特征算法的基础上混合模型进行行

为检测; 文献[5]提出基于智能手机穿戴位置无关的手机用户行为识别。

以上文献提出的方法应用在识别人体日常行为(站立、走路、跑步、上楼、下楼)中平均精度在80%~90%。虽然近年来关于传感器的研究取得了长足进步, 但在实际生活中仍然面临特征敏感度过低、噪声、成本和性能增益之间的平衡、通信限制、实际应用等方面的一些问题。

分析了上述行为识别研究, 提出如何合理地设计移动人体行为识别方法以及如何提取具有较强表征信号信息特征。在自相关函数上提取特征, 提高准确率、降低行为识别的误报率, 实现了人体日常行为数据的提取并准确地识别出人体走路、站立、跑步、上楼、下楼共五种常见人体行为。

1 人体行为识别处理

人体行为识别主要目标是输入一组或多组行为的数据, 对于各种行为的分析可以从人本身和所完成的动作特征来进行

收稿日期: 2017-02-19; **修回日期:** 2017-03-25 **基金项目:** 国家自然科学基金资助项目(61373116); 陕西省科技统筹创新工程计划项目(2016KTZDGY04-01); 陕西省教育厅资助项目(15JK1653)

作者简介: 王忠民(1967-), 男, 陕西蒲城人, 教授, 硕士, 主要研究方向为智能信息处理; 李杨(1990-), 男(通信作者), 陕西西安人, 硕士研究生, 主要研究方向为人工智能与计算机仿真(262437002@qq.com); 张荣(1975-), 男, 陕西西安人, 讲师, 硕士, 主要研究方向为模式识别等。

并且正确分析各种行为的过程。

具体流程如图1所示。



图1 行为识别处理流程

1.1 行为数据的采集

为了采集高精度的行为数据,在本次实验中统一使用小米手机4(MI4)内置的传感器。该实验设计了一个基于Android操作系统的智能手机APP用来收集人体行为训练数据(图2)。这个APP的工作流程如下:

- 选择一种指定的行为;
- 选择具体传感器;
- 设置采集时间为10 s(舍弃前2 s数据,防止噪声),频率为50 Hz。

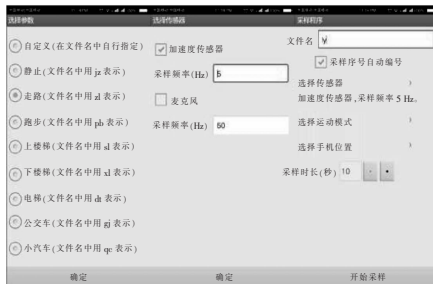


图2 采集行为数据 APP

数据采集员使用APP选择一种具体的行为,其中包括站立、走路、跑步、上楼、下楼。数据采集者共计5人(3男2女),年龄分布于20~50岁。在采集数据时,手机的位置包括手里、口袋、包里、裤兜。每一种行为追踪数据包含了三轴加速度($a_x[n]$ 、 $a_y[n]$ 、 $a_z[n]$)。

在加速度传感器采集数据时,Android允许三种不同的模式伴随着三种不同的采样频率。分别为正常模式(采样频率为5 Hz)、高级模式(采样频率为50 Hz)、快速模式(采样频率为100 Hz)。根据奈奎斯特速率在15~16 Hz时,当人体行为产生的最大信号频率为8 Hz时最适用于人体行为识别,故APP的采样频率设置为5 Hz。

1.2 预处理

该实验采取监督学习的算法作为标准机器学习形式。手机加速度传感器对于屏幕的坐标系如图3所示, x 轴水平向右, y 轴竖直向上, z 轴是指向屏幕正面之外,即屏幕背面是 z 的负值。

对于 a_x 、 a_y 和 a_z 所组成的协方差矩阵进行特征分解,以使旋转三条正交直线和三个轴 x 、 y 、 z 匹配并与轴的降序信号变化所一致。在行为识别数据中使用式(1)来计算协方差,其中 \bar{X} 为含有 n 个样本集合 X 的集合。

$$\sigma = \frac{\sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})}{n-1} \quad (1)$$

协方差矩阵 C 为

$$C = \begin{bmatrix} \sigma_x^2 & \sigma_{xy} & \sigma_{xz} \\ \sigma_{yx} & \sigma_y^2 & \sigma_{yz} \\ \sigma_{zx} & \sigma_{zy} & \sigma_z^2 \end{bmatrix} \quad (2)$$

1.3 自相关函数特征优选

根据相关研究,传感器信号可以分为时域特征、频域特征、

时频特征三大类来提取人体行为特征。

时域特征通常使用平均值(mean)、均方根(root mean square)、方差(variance)、标准差(standard)、最大值(max)、最小值(min)、中位数(median)等统计学特征对走路、站立波动范围小的行为识别效果显著^[6]。

频域特征采用快速傅里叶变换(FFT)、信息熵(entropy)和信号谱能量(energy)等特征数据对上下楼、运动波动范围大的行为识别效果显著^[7]。

时频特征采用小波能量(wavelet energy)、波峰高度(wave height)等对日常行为精度的平均值有显著的性能。

在样本数据 $R_i[n]$ ($1 \leq i \leq 3$),对于预处理后的加速度信号 D 分析,表明了概率密度函数(PDF)是符合标准正态分布的。故仅仅从常用的时域、频域、时频特征信号提取特征,其效率低下并不能满足需求。本文结合已有研究,运用笔者提出的在自相关函数提取特征加入特征集中并采用互相关函数的步进式方法进行降噪处理。

自相关函数的定义以及计算方法为:假设 X 是一个时间的随机变量序列,将不同时间起始点的两个序列 X_t 和 X_s 看成两个随机变量,则自相关函数可以定义为

$$R(s, t) = \frac{E[(X_t - \mu_t)(X_s - \mu_s)]}{\sigma_t \sigma_s} \quad (3)$$

而在特征处理过程中,一个特征的自相关函数定义为

$$R_{ff}(\tau) = [f(t)f(-t)](\tau) = \int_{-\infty}^{\infty} f(t+\tau)f(t)dt \quad (4)$$

若信号呈周期性,则当 τ 取相应的周期值时,自相关函数可以取得最大值。而自相关函数可以反映同一序列在不同时刻的取值之间的相关程度,所以可以通过在自相关函数上操作来分析特征函数的周期性。

根据式(4)计算加速度信号的自相关函数特征,将其特征添加到特征集中。预处理过后的加速度均值 \bar{d}_i 信息增益较低,其中 $1 \leq i \leq 3$ 。因此本文使用了自相关函数的均值 \bar{r}_i ($1 \leq i \leq 3$)、预处理后的加速度信号方差 $\sigma^2 d_i$ 和自相关函数的方差 $\sigma^2 r_i$ ($1 \leq i \leq 3$)。

$$r_i[t] = \frac{1}{N-1} \sum_{n=1}^N \frac{(d_i[n] - \bar{d}_i)(d_i[n+t] - \bar{d}_i)}{\sigma_i^2} \quad (5)$$

人体运动都有周期性,并且与频域信号匹配。首先尝试通过分析FFT系数信号来分离频域信号。实验表明,无论该信号在时域上是否有周期性,由噪声导致的时域信号频谱上分布没有明显的区别。

实验采取基于相关系数函数的步进式方法,对含有噪声的行为数据信号进行分解,得出频率由低到高的固有模式分呈(IMF),得到信号自相关函数和能量比,再利用阈值提取有用的噪声分量信号。

在自相关函数上进行操作来降噪,具体步骤为:

- 计算局部信号的最大值与最小值;
- 计算两种最值之间的关系差;
- 计算时差均值并求其倒数;
- 根据其倒数对上述标准化自相关函数相关性进行傅里叶变换。

最优拟合:在分析自变量和因变量之间相关关系的基础上建立变量之间的回归方程,并将回归方程作为预测模型,根据自变量在预测期的数量变化来预测因变量。建立自相关函数

$r_i[t], d_i[n] (1 \leq i \leq 3)$ 的线性拟合模型来衡量数据的变化。根据式(6)来计算最优拟合判定系数 R^2 。

$$R^2 = 1 - \frac{RSS}{TSS} \quad (6)$$

$$RSS = \sum_{i=1}^n (r_i[t] - \hat{x})^2 \quad (7)$$

$$TSS = \sum_{i=1}^n (r_i[t] - \bar{x})^2 \quad (8)$$

通过实验发现,在行为活动中,波动范围小的行为对应的 R^2 比波动范围大的行为对应的 R^2 要大。如图 4 所示,蓝色线代表自相关函数 $r_i[t] (1 \leq i \leq 3)$ 的最优线性拟合(请见电子版)。




图 3 手机坐标系




图 4 最优线性拟合

2 实验分析

2.1 分类器的选择

提取到行为数据集,将不同行为数据进行特征提取后分别送入到不同的分类器中进行分类。本文选取了朴素贝叶斯、C4.5 决策树、K 最近邻(KNN)、支持向量机(SVM)四种常用分类器进行分类。分别统计出每个分类器的识别准确率和误报率等。

2.2 实验特征集

所选取的四种分类器的输入值在整个模型中起到了决定性作用,故本文选取高增益特征作为识别人体日常行为(走路、站立、跑步、上楼、下楼)的特征集,如表 1 所示。

表 1 特征增益表

特征	特征量	特征	特征量
均值	0.20	信号谱能量	0.55
方差	0.35	自相关函数均值	0.85
标准差	0.40	自相关函数方差	0.80
拟合度	0.80	自相关函数标准差	0.90
信息熵	0.50		

2.3 实验结果分析

按照上述算法以及特征集,将所采集的数据随机选取 70% 作为训练集,剩余的 30% 作为测试集。采用十倍交叉检验,观察不同分类器对于行为识别准确率的影响。实验采用小米手机 4 内置传感器采集数据并且在 MATLAB2014a 仿真环境中进行。

基于表 1 的特征信息增益表,选取较高增益特征进行分类。对四种分类器,均采用真正率、假正率、准确率、召回率和 ROC 面积曲线来反映。

在贝叶斯的基础上进行特征因素完全无关假设得到朴素贝叶斯,即特征之间相互独立假设。将自相关函数特征加入特征集后,朴素贝叶斯假正率明显降低,平均假正率低于 20%,而准确率达到 89%,其中对站立、跑步效果显著,分别达到

了 96% 和 93%。表 2 所示为朴素贝叶斯分类准确率。

表 2 朴素贝叶斯分类准确率

行为	真正率	假正率	召回率	准确率	ROC 面积
站立	0.925	0.002	0.925	0.962	0.994
走路	0.861	0.030	0.861	0.871	0.956
跑步	1.000	0.008	1.000	0.935	1.000
上楼	0.829	0.028	0.829	0.891	0.962
下楼	0.832	0.026	0.832	0.872	0.958
平均	0.889	0.018	0.889	0.914	0.974

决策树是通过构成决策树来求取净现值的期望值大于等于零的概率。C4.5 决策树是在普通决策树算法基础上,在树的构造过程中进行剪枝,缓解过度拟合、增加了对优选特征连续值的处理、使用信息增益率来改进优选特征取值多的问题。将自相关函数特征加入特征集后,对日常行为识别准确率大大提高,尤其对走路、跑步识别效果最为显著,平均准确率达到 94.46%。表 3 所示为 C4.5 决策树分类准确率。

表 3 C4.5 决策树分类准确率

行为	真正率	假正率	召回率	准确率	ROC 面积
站立	0.976	0.050	0.976	0.900	0.970
走路	1.000	0.011	1.000	1.000	1.000
跑步	0.943	0.001	0.943	1.000	0.989
上楼	0.859	0.014	0.859	0.901	0.972
下楼	0.935	0.004	0.935	0.930	0.980
平均	0.942	0.016	0.942	0.946	0.982

K 最近邻(KNN)是一个样本在特征空间中的 K 个最相邻的样本中的大多数属于某一个类别,则该样本也属于这个类别,并具有这个类别上样本的特性。其中 $K=1$,在确定分类决策上只依据最邻近的一个或者几个样本的类别来决定待分类样本所属的类别。其包含了自相关函数特征的特征集,在 KNN 分类后发现,除了走路行为外,其他四种日常行为假正率均在 25% 以下,平均准确率为 90.7%。表 4 所示为 K 最近邻分类准确率。

表 4 K 最近邻分类准确率

行为	真正率	假正率	召回率	准确率	ROC 面积
站立	0.898	0.023	0.898	0.940	0.987
走路	0.722 2	0.030	0.792	0.871	0.956
跑步	0.914	0.024	0.914	0.891	0.982
上楼	0.889	0.018	0.889	0.921	0.988
下楼	0.912	0.012	0.912	0.915	0.985
平均	0.881	0.021	0.881	0.907	0.979

支持向量机(SVM)是建立在统计学习理论的 VC 维理论和结构风险最小原理基础上的,根据有限的样本信息在模型的复杂性(即对特定训练样本的学习精度)和学习能力(即无错误地识别任意样本的能力)之间寻求最佳折中,以获得最好的泛化能力。在使用本文提出的优选特征后,支持向量机分类后的识别结果显著,平均准确率达到 92.7%。表 5 所示为支持向量机分类准确率。

表 5 支持向量机分类准确率

行为	真正率	假正率	召回率	准确率	ROC 面积
站立	0.899	0.027	0.899	0.898	0.952
走路	0.894	0.004	0.894	0.957	0.968
跑步	0.89	0.010	0.857	0.945	0.985
上楼	0.904	0.008	0.904	0.921	0.988
下楼	0.911	0.021	0.921	0.918	0.979
平均	0.893	0.014	0.895	0.927	0.974

通过实验验证,本文提出的在自相关函数上提取特征的行

为识别方法准确率较与选取纯粹的时、频域特征集进行识别分类的模型准确率大幅提高,对人体走路、站立、跑步、上楼、下楼共五种常见人体行为准确率平均达到92%。其中C4.5决策树的平均识别准确率达到94.4%,四种分类器对站立、跑步识别效果尤为显著,相比未使用自相关函数特征的分类模型识别准确率提高了9%。包含了新特征的四种分类器在上楼、下楼识别结果最差达到了87%,但是仍比采用未包含新特征的模型识别准确率高出6%。表6所示为使用自相关函数特征前后准确率对比。

表6 使用自相关函数特征前后准确率对比(前/后)

分类模型	站立	走路	跑步	上楼	下楼
朴素贝叶斯	0.88/0.96	0.79/0.87	0.89/0.93	0.85/0.89	0.86/0.87
C4.5 决策树	0.87/0.90	0.90/1.0	0.92/1.0	0.85/0.90	0.87/0.93
K 最近邻	0.87/0.94	0.85/0.87	0.86/0.89	0.88/0.92	0.86/0.91
支持向量机	0.85/0.89	0.89/0.95	0.90/0.94	0.84/0.92	0.84/0.92

3 结束语

本文提出了一种基于智能手机传感器的人体行为识别方法,用来提高人体行为识别的准确率。该方法采用Android智能手机传感器获取人体移动过程中的行为数据,经过预处理和自相关函数特征提取、采取互相关函数的步进式方法降噪后利用决策树、朴素贝叶斯、K最近邻、支持向量机分类算法建立行为模型。通过实验验证了将自相关函数特征加入特征集中有利于提高行为识别准确率,四种分类算法平均准确率达到92%。实验结果充分证明了该方法的有效性。

参考文献:

- [1] Ghose S, Mitra J. Human activity recognition from smart-phone sensor data using a multi-class ensemble learning in home monitoring [J]. *Studies in Health Technology & Informatics*, 2015, 214: 62.
- [2] 王昌喜, 杨先军, 徐强, 等. 基三维加速度传感器的上肢动作识别系统[J]. *传感器技术学报*, 2010, 23(6): 816-819.
- [3] Gupta P, Dallas T. Feature selection and activity recognition system using a single triaxial accelerometer [J]. *IEEE Trans on Engineering*, 2014, 61(6): 1780-1786.
- [4] 王泰青, 王生进, 丁晓青. 基于最大互信息区域跟踪的人体行为检测算法[J]. *自动化学报*, 2012, 38(12): 2023-2031.
- [5] 范琳, 王忠民. 穿戴位置无关的手机用户行为识别模型[J]. *计算机应用研究*, 2015, 32(1): 63-66.
- [6] Ustev Y E, Incel O D, Ersoy C. User, device and orientation independent human activity [C]//Proc of ACM Conference on Pervasive and Ubiquitous Computing Adjunct Publication. New York: ACM Press, 2013: 1427-1436.
- [7] 李月香, 刘燕, 袁涛, 等. 基于加速度信号的走路模式多级分类算法[J]. *电子学报*, 2009, 37(8): 1794-1798.
- [8] Incel O D, Kose M, Ersoy C. A review and taxonomy of activity recognition on mobile phones [J]. *BioNanoScience*, 2013, 3(2): 145-171.
- [9] Robertas D. Human activity recognition in AAL environments using random projections [J]. *Computational & Mathematical Methods in Medicine*, 2016, 2016(6): 1-17.
- [10] Ross R, Kelleher J. A comparative study of the effect of sensor noise on activity recognition models [C]//Proc of International Joint Conference on Ambient Intelligence. Cham, Switzerland: Springer International Publishing, 2013: 151-162.
- [11] Parviainen J, Bojja J, Collin J, et al. Adaptive activity and environment recognition for mobile phones [J]. *Sensors*, 2014, 14(11): 20753-20778.
- [12] Khan A M. Exploratory data analysis of acceleration signals to select light-weight and accurate features for real-time activity recognition on smartphones [J]. *Sensors*, 2013, 13(10): 13099-13122.
- [13] Kaffle S, Dou Dejing. A heterogeneous clustering approach for human activity recognition [C]//Proc of International Conference on Big Data Analytics and Knowledge Discovery. Cham, Switzerland: Springer International Publishing, 2016: 68-81.
- [4] Frodl T, Scheuerecker J, Albrecht J, et al. Neuronal correlates of emotional processing in patients with major depression [J]. *World Journal of Biological Psychiatry*, 2009, 10(3): 202-208.
- [5] Greicius M D, Flores B H, Menon V, et al. Resting-state functional connectivity in major depression: abnormally increased contributions from subgenual cingulate cortex and thalamus [J]. *Biological Psychiatry*, 2007, 62(5): 429-437.
- [6] Sheline Y I, Price J L, Yan Zhizi, et al. Resting-state functional MRI in depression unmasks increased connectivity between networks via the dorsal nexus [J]. *Proceedings of the National Academy of Sciences*, 2010, 107(24): 11020-11025.
- [7] Zhou Yuan, Yu Chunshui, Zheng Hua, et al. Increased neural resources recruitment in the intrinsic organization in major depression [J]. *Journal of Affective Disorders*, 2010, 121(3): 220-230.
- [8] Zeng Lingli, Shen Hui, Liu Li, et al. Identifying major depression using whole-brain functional connectivity: a multivariate pattern analysis [J]. *Brain*, 2012, 135(5): 1498-1507.
- [9] Wang Jinhui, Wang Liang, Zang Yufeng, et al. Parcellation-dependent small-world brain functional networks: a resting-state fMRI study [J]. *Human Brain Mapping*, 2009, 30(5): 1511-1523.
- [10] Zalesky A, Fornito A, Harding I H, et al. Whole-brain anatomical networks: does the choice of nodes matter? [J]. *NeuroImage*, 2010, 50(3): 970-983.
- [11] Calhoun V D, Adali T, Pearlson G D, et al. A method for making group inferences from functional MRI data using independent component analysis [J]. *Human Brain Mapping*, 2001, 14(3): 140-151.
- [12] McKeown M J, Sejnowski T J. Independent component analysis of fMRI data: examining the assumptions [J]. *Human Brain Mapping*, 1998, 6(5-6): 368-372.
- [13] Allen E A, Erhardt E B, Damaraju E, et al. A baseline for the multivariate comparison of resting-state networks [J]. *Frontiers in Systems Neuroscience*, 2011, 5(5): 2.
- [14] Himberg J, Hyvärinen A, Esposito F. Validating the independent components of neuroimaging time series via clustering and visualization [J]. *NeuroImage*, 2004, 22(3): 1214-1222.
- [15] Viola P, Jones M. Robust real-time face detection [J]. *International Journal of Computer Vision*, 2004, 57(2): 137-154.
- [16] Mantini D, Perrucci M G, Gratta C D, et al. Electrophysiological signatures of resting state networks in the human brain [J]. *Proceedings of the National Academy of Sciences*, 2007, 104(32): 13170-13175.
- [17] Deseilles M, Balteau E, Sterpenich V, et al. Abnormal neural filtering of irrelevant visual information in depression [J]. *Journal of Neuroscience*, 2009, 29(47): 14935-14943.

(上接第1644页)