

考虑社会关系影响差异和动态性的社会化推荐*

赵海燕¹, 韩松¹, 陈庆奎¹, 曹健²

(1. 上海理工大学 光电信息与计算机工程学院 上海现代光学系统重点实验室, 上海 200093; 2. 上海交通大学 计算机科学与技术系, 上海 200030)

摘要: 随着社交媒体的发展, 社交活动日益普及并产生丰富的社会关系。融合社会关系进行推荐可以缓解传统推荐系统面临的数据稀疏和冷启动问题。已有很多成功利用社会关系和评分信息进行推荐的算法, 然而它们没有充分地挖掘不同的社会关系对用户的影响以及在不同时间段中社会关系的影响, 这导致推荐效果的下降。基于对现实中社会关系影响复杂性的充分考虑, 提出了新的考虑社会关系影响差异和动态性的社会化推荐算法。在 Epinions 数据集上的实验结果表明该方法可以提高推荐质量。复杂度分析也表明该方法具有可扩展性, 能够适应大数据集的要求。

关键词: 协同过滤; 社交网络; 矩阵分解; 社交信任; 差异性; 动态性

中图分类号: TP391

文献标志码: A

文章编号: 1001-3695(2018)09-2605-05

doi:10.3969/j.issn.1001-3695.2018.09.010

Social recommendation based on considerations of different effects and dynamicity of social relations

Zhao Haiyan¹, Han Song¹, Chen Qingkui¹, Cao Jian²

(1. Shanghai Key Laboratory of Modern Optical System, School of Optical-Electrical & Computer Engineering, University of Shanghai for Science & Technology, Shanghai 200093, China; 2. Dept. of Computer Science & Technology, Shanghai Jiao Tong University, Shanghai 200030, China)

Abstract: With the development of social media, social activities are more and more popular among people and rich social relations have been produced. Fusing social relations to recommend can potentially alleviate data sparse and cold start problems that traditional recommender systems face. Many successful recommendation algorithms employing both social relations and rating information have been proposed in recent years. However, these existing algorithms do not consider much on the differences of the influences generated by each social relation and the temporal changes of social factors, which degraded the performance of recommendation. Based on the fact that the social relations in the real world are very complex, this paper proposed new social recommendation algorithms that considered the different effects and dynamicity of social relations. The experimental results on Epinions dataset show that this method can improve the recommendation quality. The complexity analysis also indicates that this approach can be applied to large datasets.

Key words: collaborative filtering; social network; matrix factorization; social trust; difference; dynamicity

0 引言

随着万维网的发展, 信息正以空前的速度增长, 在线用户面临的信息过载问题也越来越严重, 因此, 能够解决信息过载问题, 为用户提供个性化推荐的推荐系统受到了广泛的关注。然而文献[1]显示商业推荐系统中用户物品评分矩阵密度通常低于1%, 数据稀疏和冷启动问题极大地降低了推荐质量。随着社交媒体的流行, 潜在上能够缓解推荐系统面临问题的社会化推荐也吸引了越来越多的关注。

狭义的社会化推荐可以定义为使用了社会关系作为附加输入的推荐, 而这种社会关系可以是信任、朋友、成员或关注关系。广义的定义是任何针对社交媒体领域内的推荐。广义的社会化推荐包含在社交媒体域内推荐任何东西, 包含物品(推荐物品是狭义定义下的推荐主要关注的)、标签、用户以及社区。广义定义下的推荐使用的来源不仅仅是线上的社交关系,

还包括各种各样的可以获得的社交媒体数据, 如社交标签、用户互动和用户点击行为等。

本文属于狭义定义下的社会化推荐, 在此定义下代表的推荐系统有 TidalTrust^[2]、MoleTrust^[3]、SoRec^[4]、SocialMF^[5]、SoReg^[6]、LOCALBAL^[7]等。然而其中大多数方法都只关注如何将社会信息与评分信息相结合, 以便作出更好的推荐。常用的结合方法有联合矩阵分解方法、正则化方法等。但是大多数方法并没有关注社会网络中这些社会关系具体的值, 或者只通过一些距离相关的因素确定其值, 如 TidalTrust 指标。另一方面, 也是因为隐私的关系, 现实中的数据只包含社会网络中的连接, 却不包含每个连接的权重。与此同时, 根据文献[8]可知, 由于社会关系形成代价低, 造成了社会关系的错杂, 如强关系与弱关系混杂在一起。根据社会相关理论可知, 如 homophily^[9] 和 social influence^[10]、用户的偏好和他们社交网络中相连接的用户相似或受他们的影响。Homophily 表明拥有相似兴趣的用户更有可能相连接, social influence 表明相连接的用户

收稿日期: 2017-04-19; **修回日期:** 2017-05-31 **基金项目:** 国家自然科学基金资助项目(61272438, 61202376, 61472253); 上海市科委资助项目(14511107702); 上海市教委科研创新项目(13ZZ112; 13YZ075)

作者简介: 赵海燕(1975-), 女, 副教授, 博士, 主要研究方向为个性化推荐、数据挖掘; 韩松(1994-), 女, 硕士, 主要研究方向为数据挖掘(Han-Song1601@163.com); 陈庆奎(1967-), 男, 教授, 博导, 主要研究方向为计算机集群、并行数据库、并行理论、网络计算等; 曹健(1972-), 男, 教授, 博导, 主要研究方向为服务计算、网络计算、大数据分析等。

户更有可能有着相似的兴趣。有理由相信,有着更强关系的用户之间要比弱联系用户之间更容易有着相似的兴趣或受影响,而同等看待社会关系将会导致推荐质量的下降。

根据以上分析,本文将从现有的数据集出发,旨在区分用户社会关系影响的不同和变化,从而更好地、更细致地还原一个真实的用户社会网络情况。

1 相关工作

目前,应用于推荐系统的技术大致可以分为基于内容、协同过滤以及混合方法。基于内容的方法根据用户过去喜欢的物品,给用户推荐相似的物品。基于协同过滤的方法根据用户过去的行为找出用户复杂的模式来预测用户的兴趣,并找出过去与该用户有着相似兴趣的用户来推荐物品。混合方法将基于内容与基于协同过滤的方法相结合。其中,基于协同过滤的方法最为流行。协同过滤方法可以分为基于邻域^[11-13]的方法和基于模型的方法两类。基于邻域的方法分为基于用户和基于物品两类。其主要问题分别在于找出相似用户、相似物品来进行推荐。而基于模型的方法则使用用户物品评分矩阵训练出一个模型来解释已有的评分数据,然后根据训练出的模型进行预测评分,不需要像基于邻域的方法来操作原始的评分数据。

随着社交媒体的发展,利用社会网络信息进行推荐的社会化推荐越来越引起人们的关注。文献[14]显示用户的社交网络集合与相似用户集合有很少的重叠,这表明社会信息为推荐提供了一个独立的信息来源,利用社会网络潜在上可以缓解数据稀疏和冷启动问题。

现有的狭义定义下的社会化推荐大多基于协同过滤技术。根据它们基于协同过滤模型的不同,又可以将社会化推荐分为基于邻域和模型的社会化推荐两类。基于邻域的社会化推荐使用基于邻域的协同过滤特别是基于用户的方法作为它们的基础模型。传统的基于用户的方法使用相似用户集合 N ,而基于邻域的社会化推荐则从评分信息和社会信息中共同获得相关用户集合 $N+$ 。不同的基于邻域的社会化推荐算法使用不同的方法来获得用户集合 $N+$ 。文献[15,16]使用均值权重的社会关系,只简单考虑直接相连的用户作为相关用户集合 $N+$ 。文献[2]设计了 TidalTrust 指标来评估用户之间的信任程度,找到从源用户出发到对某指定物品评论者之间的最短距离,并找到在这个深度范围内的所有评论用户作为 $N+$,未直接相连的用户对之间的信任值通过源用户直接信任的人对评论者的信任值计算出来。MoleTrust,类似于 TidalTrust,使用了信任传播,不同在于 MoleTrust 设置的最大深度值不依赖于任何特别的用户和物品,其信任值通过在获得的有向无环图上进行简单的随机游走得到。TrustWalker^[17]提出了结合基于信任和基于物品方法的随机游走模型,在社交网络上进行随机游走,寻找用户直接相连和非直接相连的朋友对指定物品以及及指定物品相似的物品的评分。

基于模型的社会化推荐使用基于模型的协同过滤方法作为它们的基础模型,特别是矩阵分解模型^[18,19]。SoRec 使用联合矩阵分解,共享用户特征矩阵,分解评分矩阵和信任矩阵,但这种分解信任的方式不能从理论上得到很好的解释。STE^[20]将用户对物品的评分看做是用户自身以及社会网络中用户对该物品评分的一个线性组合。相比 SoRec,STE 能更好地反映现实中推荐过程,可以从理论上得到解释。然而 STE 没有考虑信任的传播,用户直接信任的人只影响用户对某物品的评分。文献[5]中提出了 socialMF,它认为用户信任的人影响的是用户特征向量,因而社交网络中间接相邻的人也通过直接相邻的人变得相似,从而使得信任得以传播。上述算法中,SoRec

算法通过考察信任与被信任的数量情况来改变每个用户对的信任值。SoReg 算法将评分相似性作为每个用户对关于特征向量的正则项的系数,然而计算评分相似性对于数据较为稀疏的情况下并不是很适用,因为很难找到用户与朋友共同评分过的物品。其他的大多数算法也并没有区分用户信任的人影响的不同。

为此,本文将通过实验进一步分析每个用户对之间的特点和随时间的变化,从而更为准确地还原每个用户的真实社会网络,学习得到一个更为准确的用户特征矩阵和物品特征矩阵,更为准确地预测用户对物品的评分,提高推荐质量。

2 概率矩阵分解模型

为便于形式化的表示,本文用到的数学符号如表 1 所示。

表 1 数学符号

符号	意义
N	用户数目
M	物品数目
F	隐特征向量维数
$U \in R^{F \times N}$	用户特征矩阵
$V \in R^{F \times M}$	物品特征矩阵
U_u	用户 u 隐特征向量
V_j	物品 j 隐特征向量
R_{uj}	用户 U_u 对物品 V_j 的真实评分
$T_{u,k}$	用户 U_u 对用户 U_k 的信任程度
P_{uj}	用户 U_u 对物品 V_j 的预测评分
T_u	用户 U_u 信任的用户集合
B_u	用户 U_u 的行为特征向量
B_{uk}	用户 U_u 与 U_k 之间的行为相似度

假设用户物品评分矩阵中有 N 个用户、 M 个物品,评分是在 $[0,1]$ 间的。事实上,大多数推荐系统使用 $1 \sim R_{\max}$ 的整数值代表用户对物品的评价。本文为了不失统一性,使用函数 $f(x) = (x-1)/(R_{\max}-1)$ 将评分值 $1, \dots, R_{\max}$ 映射到 $[0,1]$ 区间。本文假设观测到的评分数据是符合高斯分布的,其方差为 σ_R^2 ,将已知评分数据的条件分布定义如下:

$$p(R|U, V, \sigma_R^2) = \prod_{u=1}^N \prod_{j=1}^M [N(R_{uj}|g(U_u^T V_j), \sigma_R^2)]^{I_{uj}^R} \quad (1)$$

其中: $N(x|\mu, \sigma^2)$ 是均值为 μ 、方差为 σ^2 的高斯分布的概率密度函数; I_{uj}^R 是指示函数,如果用户 u 给物品 j 打了分,那么这个值就为 1,否则为 0。式(1)中使用 logistic 函数 $g(x) = 1/(1 + \exp(-x))$ 转变 $U_u^T V_j$ 的值,并使 $U_u^T V_j$ 值限定在 $[0,1]$ 区间。同时,为了防止过拟合,假设用户和物品的特征向量是符合零均值的高斯先验的,其方差分别为 σ_U^2, σ_V^2 ,如下所示:

$$p(U|\sigma_U^2) = \prod_{u=1}^N N(U_u|0, \sigma_U^2 I) \quad (2)$$

$$p(V|\sigma_V^2) = \prod_{j=1}^M N(V_j|0, \sigma_V^2 I) \quad (3)$$

通过贝叶斯推理,隐特征变量 U 和 V 的后验概率如下:

$$P(U, V|R, \sigma_R^2, \sigma_U^2, \sigma_V^2) \propto p(R|U, V, \sigma_R^2) p(U|\sigma_U^2) p(V|\sigma_V^2) = \prod_{u=1}^N \prod_{j=1}^M [N(R_{uj}|g(U_u^T V_j), \sigma_R^2)]^{I_{uj}^R} \times \prod_{u=1}^N N(U_u|0, \sigma_U^2 I) \times \prod_{j=1}^M N(V_j|0, \sigma_V^2 I) \quad (4)$$

使用式(4)可以仅根据用户物品评分矩阵学习得到用户和物品隐特征向量。式(4)相应的图模型如图 1 所示。




图 1 概率矩阵分解图模型

对于任意 B_u, B_v , 每一维的值都是非负的, 所以 Behavior-Similarity $_{u,v}$ 的值在 $[0, 1]$ 。然而如果这样计算余弦相似度, 对

于一个没有任何购买行为的用户,他与任何有购买行为的用户之间的行为相似度都为 0,而实际上没有购买行为的用户与购买极少物品的用户之间的行为相似度应该大于与购买很多物品的用户之间的行为相似度。所以,为了改进,在建立每一个用户的行为特征向量时,每一维对应的值都加 1,再使用余弦相似度计算两两用户之间的行为相似度。

用户信任的人对用户的影响力与他们之间的行为相似度成正相关。这种正相关可以采用线性关系或指数关系来表示。本文实验将简单采用 $T_{uk} = B_{uk}$ 这种线性关系。考虑到将用户 u 对所有信任的人的信任值归一化,采用式(14):

$$T_{u,v} = \frac{B_{uv}}{\sum_{v \in T_u} B_{uv}} \quad (14)$$

归一化信任值后,便可以在迭代过程中使用基于行为相似度的信任值来代入进行计算。

3.4 Model3:TBSTPMF 模型

基于随时间变化的行为相似度的社会权重计算方法是只对基于行为相似度的方法的改进。

模型 2 中考虑的是社交网络中邻居对用户影响的不同,但是没有考虑到这种影响的变化。用户的社交网络中有新朋友,有老朋友,那么新朋友和老朋友对用户的影响是否一样呢? 用户的朋友对自己的影响是否会随着时间改变呢?

为了进一步进行实验,首先需要分时段处理数据,对于每一个时间段,都需要计算出该时间段内用户与他信任的人之间的行为相似度。然而分时段计算行为相似度,必然会导致原本稀疏的数据更稀疏。对于某些时段,如果两用户之间都没有购买行为,那么不能简单地认为他们之间的行为相似度为 1,对这种情况可以利用已知的其他时间段的数据来拟合(如多项式拟合),或用均值,或用最近时间段的数据拟合,从而填补某些时间段缺失的行为相似度。在本文实验中采用均值的方法。假设 t_2 时间段的值缺失,那么

$$\text{BehaviorSimilarity}_{u,v}(t_2) = \frac{\sum_{t \in P} \text{BehaviorSimilarity}_{u,v}(t)}{|P|} \quad (15)$$

其中: P 是有行为相似度值的时间段的集合; $|P|$ 是有值的时间段的个数。当计算好所有用户对在所有时间段的行为相似度值后,应分时间段对用户与所有他信任的人之间的行为相似度进行归一化。之后,在迭代过程中,应根据用户对物品的评分所在的时间段,选取该时间段对应的用户与所有信任的人的行为相似度值代入进行计算。如此,便考虑了用户信任的人对用户影响的变化,在不同时期采用不同的信任值,通过这种更为细致的、考虑了时间影响的方法,能够更为准确地刻画现实中的社交网络情况,从而得到更为准确的用户、物品特征矩阵,更好地为用户推荐。

4 实验和分析

本文的实验主要解决以下几个问题:

- a) 本文方法相比其他方法在推荐效果上有所提升吗?
- b) 模型的参数 λ_T 是如何影响预测的精确度的?
- c) 本文方法中三种对信任的处理方法对提升推荐的精度上的表现效果分别如何?
- d) 本文算法能否缓解冷启动和数据稀疏问题?
- e) 本文算法能够有效地处理大型数据集吗?

4.1 数据集

Epinions.com 建于 1999 年,是一个著名的知识共享和评论网站。用户可以对各个主题,如商品、电影,或者对他人的评论进行评论。用户的打分是 1~5 间的整数值。这些评分或评论将会影响将来想要购买这些商品或打算看这部电影的用户

的决定。Epinions 中每个用户都有一张信任列表,这代表着用户信任关系的社会网络。本文使用的数据集包含用户的物品评分数据以及信任关系数据。其中每条物品评分记录由用户 id、物品 id、物品所属种类 id、评分以及评分时间组成。每条信任关系由用户 id、用户信任的人 id 以及信任关系建立时间组成。这里的评分时间或信任建立时间指的是划分为 11 个时间戳后的时间,比如说, $t = \{t_1, \dots, t_{11}\}$, t_1 包含的数据是 2001 年 1 月 11 日之前的数据, t_{11} 包含 2010 年 1 月 11 日之后的数据, $t_2 \sim t_{10}$ 中每一个时间戳包含一年的数据。比如, t_2 包含了从 2001 年 1 月 12 日到 2002 年 1 月 11 日的日期。对于该数据集,本文随机抽取了一些用户进行实验分析,实验采用的数据集统计信息如表 2 所示。

表 2 Epinions 数据集统计信息

统计	Epinions	统计	Epinions
#of users	5 012	#of ratings	277 635
#of items	82 326	#of trust relations	15 229

4.2 实验度量方法

实验采用了两个评价指标,分别是绝对误差 MAE 和均方根误差 RMSE。其定义如式(16)(17)所示。

$$\text{MAE} = \frac{\sum_{u,j} |R_{uj} - \hat{R}_{uj}|}{|\text{test}|} \quad (16)$$

$$\text{RMSE} = \sqrt{\frac{\sum_{u,j} (R_{uj} - \hat{R}_{uj})^2}{|\text{test}|}} \quad (17)$$

其中: R_{uj} 代表用户 U_u 对物品 V_j 的真实评分; \hat{R}_{uj} 代表用户 U_u 对物品 V_j 的预测评分; $|\text{test}|$ 代表测试集中用户物品评分数据数目。

将本文算法(使用第 3 章提出的三种信任处理方法)与下面的算法进行比较:

- a) PMF。该算法仅使用用户物品评分数据。
- b) SocialMF。综合使用社会关系和评分信息。

4.3 参数 λ_T 的影响

式(9)中参数 λ_T 控制着本文方法利用社会网络的程度。在极端情况下,如果使用一个很小的 λ_T 值,就相当于只使用了用户物品评分信息,在推荐时只用了用户自身的偏好。在另一种极端情况下,如果 λ_T 设置得很大,那么社交网络信息将会主导学习过程。大多数情况下,不会将 λ_T 设置成这些极端的值,因为这会降低推荐的质量。

本节将分别实现第 3 章提出的三种方法,分析 λ_T 的变化对推荐精度的影响。

本文所有实验将使用 90% 的 Epinions 数据作为训练集,10% 数据作为测试集,设置隐特征向量维数 $F=5$ 。

图 3、4 分别是 ASTPMF 方法中不同 λ_T 对应的 MAE 和 RMSE 值。图 5、6 分别是 BSTPMF 方法中不同 λ_T 对应的 MAE 和 RMSE 值。图 7、8 分别是 TBSTPMF 方法中不同 λ_T 对应的 MAE 和 RMSE 值。MAE、RMSE 是 4.2 节中介绍的两种不同的实验效果度量方法,度量的预测评分的精度。根据对图 3~8 的观察可知,正则化参数 λ_T 的值影响着推荐的精度, λ_T 的最佳取值在 $[1, 10]$ 内,并且 MAE、RMSE 的变化趋势是随着 λ_T 的增加先减小后增加的。




图 3 ASTPMF 中不同 λ_T 对应的 MAE 值








图 4 ASTPMF 中不同 λ_T 对应的 RMSE 值

图5 BSTPMF 中不同 λ_T 对应的 MAE 值图6 BSTPMF 中不同 λ_T 对应的 RMSE 值图7 TBSTPMF 中不同 λ_T 对应的 MAE 值图8 TBSTPMF 中不同 λ_T 对应的 RMSE 值

4.4 对比实验分析

在 4.1 节描述的 Epinions 数据集上进行了对比实验,结果如表 3 所示。

表3 90%训练集和10%测试集中不同算法的 MAE、RMSE 值

model	$F=5$	
	MAE	RMSE
PMF	0.979	1.231
SocialMF	0.950	1.196
ASTPMF	0.935	1.173
BSTPMF	0.921	1.158
TBSTPMF	0.912	1.145

根据表 3,可以得到如下结论:

a) 本文方法 ASTPMF、BSTPMF、TBSTPMF 相比于 PMF 在 MAE 值上分别提高 4.5%、5.9%、6.8%;在 RMSE 值上分别提高 4.7%、5.9%、7.0%。ASTPMF、BSTPMF、TBSTPMF 相比于 SocialMF 在 MAE 值上分别提高 1.6%、3.1%、4.0%,在 RMSE 值上分别提高了 1.9%、3.2%、4.3%。由此可见,本文提出的融合社会关系的概率矩阵分解算法要优于 PMF 和 SocialMF。

b) 基于随时间变化的行为相似度的社会关系权重计算方法 TBSTPMF 要优于仅基于行为相似度的 BSTPMF,基于行为相似度的 BSTPMF 又要优于均值社会信任权重的 ASTPMF。

4.5 计算复杂度分析

学习参数的主要代价花费在目标函数 \mathcal{L} 的计算和对用户、物品特征向量的求导上。假设每个用户平均有 \bar{r} 个评分数据,每个用户直接信任的邻居个数为 \bar{t} 个,那么目标函数 \mathcal{L} 的复杂度为 $O(N\bar{r}F + N\bar{t}F)$ 。因为评分矩阵 R 和信任矩阵 T 都是非常稀疏的, \bar{r} 和 \bar{t} 的值都相当小,所以目标函数 \mathcal{L} 的计算很快,并且随着社交评分网络中用户的数目线性增长。 $\frac{\partial \mathcal{L}}{\partial U}$ 、 $\frac{\partial \mathcal{L}}{\partial V}$ 的复杂度分别为 $O(N\bar{r}F + N\bar{t}F + N\bar{r}^2F)$ 、 $O(N\bar{r}F + N\bar{t}F)$,这也是关于社交评分网络中用户数目线性增长的。而本文提出的关于信任值的三种计算方法在迭代之前便已计算好,是一个常数值。复杂度分析表明本文提出的方法是具有可扩展性的,能够运用到大规模的数据集上。

5 结束语

本文从现实出发,考虑了现实中社会网络中的朋友在推荐时产生的影响的不同和变化。基于此本文提出了一种新的基于概率矩阵分解的方法,对于信任的人对本文的影响采用了三种方式进行处理,即没有区分朋友影响的不同、基于行为相似度计算出朋友的影响的权重,以及考虑了朋友对自己影响的变化,使用了随时间变化的行为相似度来计算。实验结果表明,充分挖掘朋友的影响的不同及其变化,可以帮助还原用户更为

真实的社会网络,从而可以帮助学习得到更为准确的用户、物品特征矩阵,提高推荐精度。相比其他流行的算法,本文模型都有一定的改善,复杂度分析也显示本文算法具有可扩展性,可以处理大型数据集。下一步将会进一步研究用户的社会关系是如何随时间变化的,从而更好地构建用户的社会网络与时间相关的模型,进一步提高推荐的精度。

参考文献:

- [1] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms[C]//Proc of the 10th International Conference on World Wide Web. New York: ACM Press, 2001: 285-295.
- [2] Golbeck J A. Computing and applying trust in Web-based social networks[D]. Maryland: University of Maryland at College Park, 2005.
- [3] Massa P, Avesani P. TrustAware recommender systems[C]//Proc of ACM Conference on Recommender Systems. New York: ACM Press, 2007: 17-24.
- [4] Ma Hao, Yang Haixuan, Lyu M R, et al. Sorec: social recommendation using probabilistic matrix factorization[C]//Proc of the 17th ACM Conference on Information and Knowledge Management. New York: ACM Press, 2008: 931-940.
- [5] Jamali M, Ester M. A matrix factorization technique with trust propagation for recommendation in social networks[C]//Proc of the 4th ACM Conference on Recommender Systems. New York: ACM Press, 2010: 135-142.
- [6] Ma Hao, Zhou Dengyang, Liu Chao, et al. Recommender systems with social regularization[C]//Proc of the 4th ACM International Conference on Web Search and Data Mining. New York: ACM Press, 2011: 287-296.
- [7] Tang Jiliang, Hu Xia, Gao Huiji, et al. Exploiting local and global social context for recommendation[C]//Proc of the 23rd International Joint Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2013: 264-269.
- [8] Xiang Rongjing, Neville J, Rogati M. Modeling relationship strength in online social networks[C]//Proc of the 19th International Conference on World Wide Web. New York: ACM Press, 2010: 981-990.
- [9] McPherson M, Smith-Lovin L, Cook J M. Birds of a feather; homophily in social networks[J]. *Annual Review of Sociology*, 2001, 27(1): 415-444.
- [10] Marsden P V, Friedkin N E. Network studies of social influence[J]. *Sociological Methods & Research*, 1993, 22(1): 127-151.
- [11] Koren Y. Collaborative filtering with temporal dynamics[J]. *Communications of the ACM*, 2010, 53(4): 89-97.
- [12] 项亮. 推荐系统实践[M]. 北京: 人民邮电出版社, 2012: 44-64.
- [13] Liu Haifeng, Hu Zheng, Mian A, et al. A new user similarity model to improve the accuracy of collaborative filtering[J]. *Knowledge-Based Systems*, 2014, 56(1): 156-166.
- [14] Tang Jiliang, Gao Huiji, Hu Xia, et al. Context-aware review helpfulness rating prediction[C]//Proc of the 7th ACM Conference on Recommender Systems. New York: ACM Press, 2013: 1-8.
- [15] Victor P, Cornelis C, De Cock M, et al. A comparative analysis of trust-enhanced recommenders for controversial items[C]//Proc of the 3rd International Conference on Weblogs and Social Media. [S. l.]: ICWSM Press, 2009: 342-345.
- [16] Victor P, De Cock M, Cornelis C. Trust and recommendations[M]//Recommender Systems Handbook. Berlin: Springer, 2011: 645-675.
- [17] Jamali M, Ester M. TrustWalker: a random walk model for combining trust-based and item-based recommendation[C]//Proc of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM Press, 2009: 397-406.
- [18] Mnih A, Salakhutdinov R. Probabilistic matrix factorization[C]//Advances in Neural Information Processing Systems. 2008: 1257-1264.
- [19] Luo Xin, Zhou Mengchu, Xia Yunni, et al. An efficient non-negative matrix-factorization-based approach to collaborative filtering for recommender systems[J]. *IEEE Trans on Industrial Informatics*, 2014, 10(2): 1273-1284.
- [20] Ma Hao, King I, Lyu M R. Learning to recommend with social trust ensemble[C]//Proc of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM Press, 2009: 203-210.