

基于模糊聚类和改进混合蛙跳的协同过滤推荐*

许智宏^{1,2}, 田雨¹, 闫文杰^{1,2}, 暴利花¹

(1. 河北工业大学 计算机科学与软件学院, 天津 300401; 2. 河北省大数据计算重点实验室, 天津 300401)

摘要: 由于传统的协同过滤推荐算法存在很多缺陷,如数据稀疏性、冷启动、低推荐精度等,提出了一种基于模糊聚类和改进混合蛙跳的协同过滤推荐算法。首先利用一种构造的基于时间的指数遗忘函数对原始评分数据进行处理;然后根据得到的基于时间衰退的评分矩阵对用户进行模糊C-均值(FCM)聚类,并找出与目标用户有较高相似性的前几个类作为候选邻居集;再用改进的混合蛙跳算法找到最近邻居集;最后求出目标用户对未参与项目的预测评分。经实验证明,该算法比其他一些算法的推荐精度要高,且由于数据稀疏性引起的不良影响也得到了有效的缓解。

关键词: 协同过滤推荐;指数遗忘函数;模糊C-均值聚类;混合蛙跳算法

中图分类号: TP301.6 **文献标志码:** A **文章编号:** 1001-3695(2018)10-2908-04

doi:10.3969/j.issn.1001-3695.2018.10.006

Collaborative filtering recommendation based on fuzzy clustering and improved shuffled frog leaping algorithm

Xu Zhihong^{1,2}, Tian Yu¹, Yan Wenjie^{1,2}, Bao Lihua¹

(1. School of Computer Science & Engineering, Hebei University of Technology, Tianjin 300401, China; 2. Hebei Province Key Laboratory of Big Data Calculation, Tianjin 300401, China)

Abstract: As the traditional collaborative filtering recommendation algorithm existed many defects, such as data sparseness, cold start and low recommendation accuracy, this paper proposed a collaborative filtering recommendation algorithm based on fuzzy clustering and improved shuffled frog leaping algorithm. The algorithm first used the constructed time-based exponential forgetting function to process the original score. Then, it clustered the users with fuzzy C-means (FCM) clustering according to the obtained scoring matrix based on time lag, and found the first few classes with higher similarity to the target user as candidate neighbor sets. And then it used the improved shuffled frog leaping algorithm to find the nearest neighbor sets. Finally, it calculated the prediction score of the target user was not involved in the project. Experiments show that the proposed algorithm is more accurate than some other algorithms, and effectively alleviate the adverse effects due to data sparseness.

Key words: collaborative filtering recommendation; exponential forgetting function; fuzzy C-means clustering; shuffled frog leaping algorithm

0 引言

随着互联网、物联网的不断崛起及 Web 2.0 技术的快速发展,网络信息资源日益丰富并趋于多元化,网上数据呈指数爆炸性增长态势^[1],日均新增数据已达 TB 级,导致了非常严峻的“信息超载”问题,因此个性化推荐系统不断盛行起来。其中,应用最广泛、技术最成功的是协同过滤(collaborative filtering, CF)推荐。但由于网络的普及,出现了越来越多的用户和项目,随之而来的数据稀疏、冷启动问题使得传统的 CF 算法在推荐精度上持续下降。

为解决以上问题,众多研究者对原始算法进行了各种研究与改进。为缓解稀疏性问题, Song Meiqing^[2]采用多维数据填充; Wei 等人^[3]采用双向聚类平滑填充,但算法复杂度较高;于洪等人^[4]提出了一种解决新项目冷启动问题的算法; Zhang 等人^[5]将结构约束用于用户兴趣建模,提高了推荐效果;吴月萍等人^[6]在 CF 中运用了群集智能算法,为后来研究人员提供了新方向;邵琳琳^[7]对用户进行模糊聚类后,为找到用户的最近

邻居集使用了混合蛙跳算法,推荐精度得到提高,但算法会过早收敛;喻金平等^[8]根据用户和项目联合聚类的结果填充稀疏矩阵,再利用改进的混合蛙跳算法寻找项目最近邻居集,有效缓解了数据稀疏性问题。

为进一步解决传统 CF 算法的缺陷,本文构造了一种基于时间的指数遗忘函数,并使用了 FCM 和混合蛙跳算法,提出了一种基于模糊聚类和改进混合蛙跳的 CF 推荐算法(FISCF)。

1 CF 算法

1.1 数据模型

设 $D = (U, P, R)$, 其中 $U = \{u_1, u_2, \dots, u_m\}$ 为 m 个用户组成的集合; $P = \{p_1, p_2, \dots, p_n\}$ 为 n 个项目组成的集合; $R_{m \times n} = \{r_{ij} | i \in [1, m], j \in [1, n]\}$ 为 m 个用户对 n 个项目的评分矩阵。

1.2 相似性度量

常见的相似性度量方法有余弦相似性、修正的余弦相似

收稿日期: 2017-05-26; 修回日期: 2017-07-16 基金项目: 河北省自然科学基金资助项目(F2015202214); 河北省科技计划资助项目(15210506); 天津市自然科学基金资助项目(16JCQNJC00400)

作者简介: 许智宏(1970-), 女, 河北张家口人, 副教授, 博士, 主要研究方向为分布式计算、智能信息处理(xuzhihong@scse.hebut.edu.cn); 田雨(1990-), 女, 硕士研究生, 主要研究方向为智能信息处理、分布式计算; 闫文杰(1983-), 男, 讲师, 博士, 主要研究方向为 WMSN、压缩感知、视频编码和大数据分析; 暴利花(1990-), 女, 硕士研究生, 主要研究方向为分布式计算、数据挖掘。

性、Pearson 相关相似性等。余弦相似性是用向量空间中两个向量夹角的余弦值作为衡量两个个体间差异的大小,但没有考虑到用户评分尺度问题。通过减去用户对项目的平均评分,修正的余弦相似性方法改善了以上问题。Pearson 相关系数反映了两个变量之间的线性相关程度,但没有考虑到用户间重叠的评分项数量对相似性的影响,特别是当项目的共同评分数量较少的时候, Pearson 相关系数并不能很好地反映两个向量之间的相似程度,若两个用户之间只有一个共同的评分项,则相似度不能被计算。因本文所用数据较稀疏,为提高其推荐精度,本文对用户相似性的度量方法选择使用修正的余弦相似性。其公式为

$$\text{sim}(a, b) = \frac{\sum_{c \in P_{ab}} (R_{ac} - \bar{R}_a)(R_{bc} - \bar{R}_b)}{\sqrt{\sum_{c \in P_a} (R_{ac} - \bar{R}_a)^2} \sqrt{\sum_{c \in P_b} (R_{bc} - \bar{R}_b)^2}} \quad (1)$$

其中: P_{ab} 为用户 a, b 都参与评分的项目集; R_{ac}, R_{bc} 分别表示用户 a, b 对项目 c 的评分; \bar{R}_a, \bar{R}_b 分别表示用户 a, b 对所有参与评分项目的评分均值。

1.3 预测评分

找出与目标用户 a 有较高相似度的前 N 个用户,作为最近邻居集 $Q_U^a = \{u'_1, u'_2, \dots, u'_N\}$, 则预测用户 a 对还没有参与评分的项目 e 的评分 PR_{ae} 为

$$PR_{ae} = \bar{R}_a + \frac{\sum_{b \in Q_U^a} \text{sim}(a, b) (R_{be} - \bar{R}_b)}{\sum_{b \in Q_U^a} |\text{sim}(a, b)|} \quad (2)$$

1.4 修正的数据模型

每个人都有自己的兴趣偏好,并且不是一成不变的。随着时间的推移,由于所处环境的变化、自身认识的开阔以及社会形式的影响,每个人的兴趣偏好也会相应改变。推荐系统中,用户在不同时期、不同环境对同一个项目的评分是有差异的。传统的基于用户的 CF 算法并没有将此问题考虑到对算法的影响中,无论是最早评论的或是最晚评论的,对原始评分数据的使用都没有进行分别处理,很大程度上降低了推荐精度。根据艾宾浩斯遗忘曲线及其他遗忘函数^[9-12],构造一种基于评分时间差的指数遗忘函数,并对用户评分进行不同程度的衰减,从而实现基于用户偏好随时间变化的推荐效果,可以提高推荐质量。

本文符号定义如下:

t 表示用户对项目的评分时间。

T_{start} 表示用户第一次对项目参与评分的时间。

T_{end} 表示用户最近一次对项目参与评分的时间。

eps 表示最小值,设 $\text{eps} = 0.000\ 001$ 。现实生活中可能会出现这样一种情况:一些用户的第一次评分与最后一次评分为同一天。为避免这种情况发生时导致的构造函数的错误性而特设此值。

基于时间的指数遗忘函数可表示为

$$f(t) = e^{\frac{t - T_{\text{start}}}{T_{\text{end}} - T_{\text{start}} + \text{eps}}} - 1 \quad (3)$$

由上式可知, $e^{-1} \leq f(t) < 1$, 用户对项目评分的时间越新, $f(t)$ 越大,评分衰减的程度越小;反之,评分的衰减程度越大。根据式(3)对用户评分进行衰减,得到修正的评分矩阵,既提高了近期评分的重要性,又减小了最远评分的重要性。之后用修正的评分矩阵代替原始的评分矩阵进行数据建模。

2 基于模糊聚类和改进混合蛙跳的 CF 算法

2.1 模糊 C-均值聚类算法

模糊聚类属于软聚类,其中被广泛使用且聚类效果较好的是模糊 C-均值(FCM)聚类。推荐系统中,根据隶属度的不同,

一个用户可能被聚到多个类中^[13]。若将用户集 U 聚为 C ($C \in [2, m]$) 类,那么可将聚类中心表示为 $V = \{v_1, v_2, \dots, v_i, \dots, v_C\}$, 用户 u_k 对聚类中心 v_i ($i = 1, 2, \dots, C$) 的隶属度为 μ_{ik} ($\mu_{ik} \in [0, 1]$), 则聚类结果为 $H_{m \times C} = (\mu_{ik})$ 。FCM 聚类的目标函数可表示为

$$\min J_{\text{FCM}}(H, V) = \sum_{k=1}^m \sum_{i=1}^C (\mu_{ik})^M \|u_k - v_i\|^2 \quad (4)$$

其中: M 表示模糊加权指数,通常 $M \in [1.25, 2.5]$ 。

$$d_{ik} = \|u_k - v_i\|^2 \quad (5)$$

$$\mu_{ik} = \frac{1}{\sum_{j=1}^C \left(\frac{d_{ik}}{d_{jk}}\right)^{\frac{2}{M-1}}} \quad (6)$$

$$v_i = \frac{\sum_{k=1}^m (\mu_{ik})^M u_k}{\sum_{k=1}^m (\mu_{ik})^M} \quad (7)$$

约束条件为

$$\sum_{i=1}^C \mu_{ik} = 1 \quad (8)$$

用 FCM 对用户聚类的具体步骤为:

a) 设置模糊聚类数 C 、模糊加权指数 M ;

b) 随机生成初始聚类中心;

c) 用式(6)求得用户的隶属度矩阵;

d) 用式(7)求各类的聚类中心;

e) 如果迭代前后两次的 $J(H, V)$ 差比最初设置的最小值小,则迭代停止,否则转到步骤 c) 继续执行;

f) 输出用户的最优聚类中心和隶属度矩阵。

根据以上输出的最优聚类中心,求出其与目标用户的相似度,选择值较高的前几个聚类组成候选邻居集,再用改进的混合蛙跳算法求出最近邻居集。

2.2 改进的混合蛙跳算法

2.2.1 混合蛙跳算法

Eusuff 和 Lansey^[14] 结合 PSO 和 MA 算法的优点,解决了组合优化问题,并在 2003 年提出了一种新型的群集智能算法——混合蛙跳算法(shuffled frog leaping algorithm, SFLA)。其主要由三部分^[15]组成。

1) 族群划分

初始化 F 只青蛙群 $P = \{P_1, P_2, \dots, P_k, \dots, P_F\}$ ($k = 1, 2, \dots, F$), 其中每一只青蛙都表示目标函数的一个 d 维解($P_k = (p_{k1}, p_{k2}, \dots, p_{kd})$)。按每只青蛙的适应度值 $f(P_k)$ 递减的方式对其排列,得到全局最优解 P_g 。按照图 1 的方式将排序后的青蛙群分成 m 组,每组中有 n 只。在每组中找出适应度最好的青蛙 P_b 和最差的青蛙 P_w 。




图1 蛙群的具体分组规则

2) 局部搜索

青蛙群分组后开始局部搜索,也就是根据式(9)更新每组中最差的青蛙 P_w 。

$$\begin{cases} S = \text{rand}() \times (P_b - P_w) \\ \text{new}P_w = P_w + S \quad -S_{\text{max}} \leq S \leq S_{\text{max}} \end{cases} \quad (9)$$

其中: $\text{rand}() \in [0, 1]$; S_{max} 为青蛙最大可以跳跃的步长。

更新规则为:如果原来最差的青蛙 P_w 不如更新后的青蛙 $\text{new}P_w$ 好,则 $\text{new}P_w = P_w$;否则,用 P_g 代替 P_b 并按式(9)重新更新 P_w ,如果 $\text{new}P_w$ 比 P_w 好,则 $\text{new}P_w = P_w$;否则,将 P_w 用一

只随机生成的新青蛙替代。重复以上步骤,当达到局部最大迭代次数时停止更新。

3) 全局信息交换

每组都完成一遍局部搜索后,将所有组都组合在一起组成一个新的青蛙群,按照新青蛙群的 $f(P_k)$ 递减的顺序排列青蛙,更新 P_g 并执行局部搜索,当满足收敛条件或达到全局最大迭代次数时停止。

2.2.2 改进的混合蛙跳算法

SFLA 与其他群集智能算法相比思想较简单,算法运行中需调整的因子数很少。青蛙是有好坏之分的,但其最差青蛙的步长更新规则比较单一,容易陷入局部最优解。SFLA 能够收敛于全局最优解是基于每组的局部搜索和全局的信息交流。搜索的过程中,青蛙的跳动步长受随机数 $\text{rand}()$ 的影响,其大小影响着 SFLA 的运算速率和搜索精度。因此青蛙每次跳动的步长不易过大或是过小,若太小,其能够在较小的局部范围内仔细搜索,却造成寻优速度变慢,易陷入局部最优状态;反之,在较大区域搜索,寻优速度有所提高,却很难找到全局最优的位置。显然,改善步长的更新规则十分重要。

本文提出了一种改进的混合蛙跳算法 (ASFLA),根据青蛙的 $f(P_k)$ 大小、 P_w 与 P_g 或 P_b 距离的远近和局部以及全局迭代的进化指标自适应调整更新策略,提出了新的更新规则。

在每组的迭代中,适应度值是衡量新青蛙是否要更新旧青蛙的准则。因此在每组的迭代中,可将适应度值之间的差异及迭代进化指标看做步长的加速度。

首先引入迭代进化指标 (H), 定义为

$$H = \frac{B-b}{B} \quad (10)$$

其中: b 为局部的当前迭代次数; B 为局部的最大迭代次数。

提出的自适应跳动步长的更新规则如下:

$$S = \text{rand}() \times \frac{f(P_b) - f(P_w)}{f(P_w) + \text{eps}} \times \frac{B-b}{B} \times (P_b - P_w) \quad (11)$$

其中: $f(P_b)$ 和 $f(P_w)$ 分别为每组中最优和最差青蛙的适应度值。由于青蛙群是随机初始化生成的,考虑到最差青蛙的位置可能偏很远,其 $f(P_k)$ 值可能会很小,为避免分母为 0,本文设 $\text{eps} = 0.000\ 001$ 为最小值。

在 ASFLA 中,称 $\frac{f(P_b) - f(P_w)}{f(P_w) + \text{eps}} \times \frac{B-b}{B}$ 为自适应系数,能够自主地调节蛙的跳跃步长。在迭代一开始, $f(P_w)$ 、 b 较小,则 $\frac{f(P_b) - f(P_w)}{f(P_w) + \text{eps}} \times \frac{B-b}{B}$ 较大,所以青蛙的步长较大,在大范围内搜索加快了寻优速度;随着迭代次数的加大, $f(P_w)$ 、 b 增大,则 $\frac{f(P_b) - f(P_w)}{f(P_w) + \text{eps}} \times \frac{B-b}{B}$ 较小,所以青蛙的步长较小,青蛙可以在较小的局部范围内仔细搜索,便于搜索到更精确的最优值。

同理,当用局部最优解 P_b 更新最差解 P_w 没有得到改善时,用种群最优解 P_g 替代 P_b 更新步长,表达式为

$$S = \text{rand}() \times \frac{f(P_g) - f(P_w)}{f(P_w) + \text{eps}} \times \frac{G-g}{G} \times (P_g - P_w) \quad (12)$$

其中: $f(P_g)$ 为青蛙群中最优蛙的适应度值; g 为全局的当前迭代次数; G 为全局的最大迭代次数。

青蛙通过以上更新规则自适应改变其跳动步长, ASFLA 的收敛速度和精度都有所提高。

2.2.3 ASFLA 求解最近邻集合

ASFLA 解决组合优化问题主要有两步,即青蛙编码和确定适应度函数。用 ASFLA 求解最近邻居集同样也要解决这两个问题。

为在推荐系统中应用 ASFLA,需特殊编码,即 $p_{kj} = 0$ 或

$p_{kj} = 1$, 且每只青蛙中“1”的个数为 N 。例如 $P_g = (0, 1, 1, 0, 0, 1)$, 表示从六个候选邻居中选三个作为最近邻居时,选择用户 2、3、6。

适应度函数定义为目标用户 a 与最近邻集合 Q_v^a 的相似度值,即

$$f(Q) = \sum_{j=1}^d u_{aj} \text{sim}(a, b) \quad (13)$$

ASFLA 求解最近邻居集的具体流程如图 2 所示。

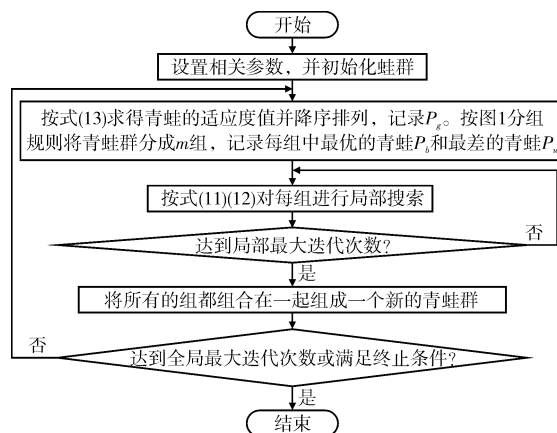


图 2 ASFLA 求解最近邻居集的流程

由此,先用 FCM 算法对用户模糊聚类得到候选邻居集,再用 ASFLA 得到最近邻居集。

2.3 基于模糊聚类和改进混合蛙跳的 CF 算法

本文在传统的 CF 算法中主要运用了 FCM 算法、ASFLA。首先,构造了一种基于时间的指数遗忘函数,用此函数处理评分得到基于时间衰退的评分矩阵;然后用 FCM 对用户进行模糊聚类得到最优聚类中心,通过求其与目标用户的相似度得到候选邻居集;再利用 ASFLA 在候选邻居集中求出最近邻居集,根据其对项目的评分,预测目标用户对没有参与的项目进行评分,得到推荐结果。FISCF 算法的具体步骤可描述为如下几步:

- 数据建模,根据式(3)计算用户对项目基于时间的衰退评分;
- 用 FCM 对用户模糊聚类,得到最优聚类中心;
- 根据式(1)计算目标用户与聚类中心的相似性,选择值较高的前几个聚类组成候选邻居集;
- 用 ASFLA 寻找最近邻居集;
- 计算目标用户对没有参与的项目的预测评分,得到推荐结果。

3 实验与结果分析

3.1 实验环境

本文实验的硬件环境为: Intel® 酷睿 i5 双核处理器, 2.50 GHz CPU, 10 GB 内存;软件环境为 R × 64 3.3.1 版本,在 R-Studio 中编写。

3.2 实验数据

本文实验所用的数据集是从 <http://grouplens.org/datasets/movielens/> 网站获取的 MovieLens 电影评分数据集,主要有五个部分,本文采用 ml-lastest-small 这个数据。该数据集中有较新的用户评分,其包含了截至 2016 年 10 月份更新的 700 个用户对 9 000 部电影的 100 000 条评分数据,且任何一个用户对电影的评分都不少于 20 条。实验中将数据集分为训练集和测试集两部分。

3.3 评价指标

在推荐系统中,通常使用平均绝对误差(MAE)评价预测评分的准确度,其值越小,说明推荐结果越好。若目标用户对项目的预测评分集为 $PR = \{PR_1, PR_2, \dots, PR_n\}$,实际评分集为 $R = \{R_1, R_2, \dots, R_n\}$,则 MAE 计算公式为

$$MAE = \frac{\sum_{i=1}^n |PR_i - R_i|}{n} \quad (14)$$

3.4 仿真实验

实验 1 为验证使用修正的评分矩阵优于原始的评分矩阵,在最近邻居个数分别取(10,20,30,40,50,60)的情况下,将基于评分时间差的 CF 算法与传统 CF 算法相比较,其 MAE 结果如图 3 所示。




图3 基于评分时间差的CF算法与传统CF算法比较

实验结果表明,根据式(3)进行评分衰减后得到修正的评分矩阵,用其代替原始的评分矩阵进行数据建模,使得推荐质量得到显著提高。

实验 2 FISCf 算法参数设置为: $M=2, F=200, m=20, n=10$,局部迭代次数为 50,全局迭代次数为 500。为测试不同聚类个数对推荐结果的影响,在最近邻居个数取 60,聚类个数 C 分别取(10,20,30,40,50,60)的情况下,用 FISCf 算法和 IC-FRA^[7]进行实验,其 MAE 结果如图 4 所示。




图4 用户聚类数对MAE值的影响

两种算法都表明,聚类个数的不同影响着推荐精度的高低。聚类个数增大时,MAE值也不断增大,即推荐精度越来越小,所以聚类数不能取值很大,根据实验结果,选取聚类数为10最合适。

实验 3 为进一步验证 FISCf 算法的有效性,根据以上实验结论,取聚类个数为 10,在最近邻居个数分别取(10,20,30,40,50,60)的情况下,将 FISCf 算法与传统的 CF 算法、ICFRA 作比较,得到的仿真结果如图 5 所示。




图5 各算法精度比较

实验结果表明,当最近邻居的个数增多时,每种算法的MAE值都有所降低,即推荐结果的准确度都有提升。本文的FISCf算法的MAE值比其他两种算法要小,说明在对原始评分进行遗忘衰减处理后,减小了由于时间推移导致兴趣变化所带来的影响,使用改进的ASFLA求出的最近邻居集更准确,使得其推荐结果更准确。

4 结束语

由于传统CF算法在数据稀疏性、冷启动、低推荐精度等方面的严重缺陷,本文提出了基于模糊聚类和改进混合蛙跳的协同过滤算法FISCf。首先用构造的指数遗忘函数对评分数据进行处理,有效缓解了由于用户兴趣的变化导致推荐不准确的问题;并用FCM算法对用户进行模糊聚类,有效缓解了数据稀疏性问题;然后用改进的ASFLA求出目标用户的最近邻居集,有效地提高了推荐精度和速度。下一步将主要研究在Spark分布式平台上,更大数据规模时的推荐精度和速度。

参考文献:

- [1] 郭磊, 马军, 陈竹敏. 一种信任关系强度敏感的社会化推荐算法[J]. 计算机研究与发展, 2013, 50(9): 1805-1813.
- [2] Song Meiqing. A collaborative filtering recommendation algorithm based on multi-dimensional data filling [C]//Proc of the 2nd IEEE International Conference on Computer and Communications. Piscataway, NJ: IEEE Press, 2016: 175-179.
- [3] Wei Suyun, Ye Ning, Zhang Shuo, et al. Collaborative filtering recommendation algorithm based on item clustering and global similarity [C]//Proc of the 5th International Conference on Business Intelligence and Financial Engineering. Washington DC: IEEE Computer Society, 2012: 69-72.
- [4] 于洪, 李俊华. 一种解决新项目冷启动问题的推荐算法[J]. 软件学报, 2015, 26(6): 1395-1408.
- [5] Zhang Qing, Wang Houfeng. Improving collaborative filtering via hidden structured constraint [C]//Proc of the 24th ACM International on Conference on Information and Knowledge Management. New York: ACM Press, 2015: 1935-1938.
- [6] 吴月萍, 杜奕. 基于人工鱼群算法的协同过滤推荐算法[J]. 计算机工程与设计, 2012, 33(5): 1852-1856.
- [7] 邵琳琳. 基于混合蛙跳模糊聚类的电子商务协同过滤推荐[J]. 科学技术与工程, 2013, 13(12): 3452-3456.
- [8] 喻金平, 张勇, 廖列法, 等. 基于混合蛙跳联合聚类的协同过滤算法[J]. 微电子学与计算机, 2016, 33(1): 65-71.
- [9] Sun Limei, Michael E I, Wang Shen, et al. A time-sensitive collaborative filtering model in recommendation systems [C]//Proc of IEEE International Conference on Internet of Things. Piscataway, NJ: IEEE Press, 2016: 340-344.
- [10] 刘荣荣. 考虑时间情境的群体推荐算法研究[J]. 武汉理工大学学报: 信息与管理工程版, 2016, 38(1): 93-96.
- [11] 张红霞, 杨渊, 郎维. 基于客户行为和兴趣变化的电子商务推荐系统[J]. 宝鸡文理学院学报: 自然科学版, 2012, 32(2): 52-56.
- [12] Cao Jingjing, Li Wenfeng. Sentimental feature based collaborative filtering recommendation [C]//Proc of IEEE International Conference on Big Data and Smart Computing. Piscataway, NJ: IEEE Press, 2017: 463-464.
- [13] Taufik A, Ahmad S S S, Khairuddin N F E. Classification of Landsat 8 satellite data using fuzzy C-means [C]//Proc of International Conference on Machine Learning and Soft Computing. New York: ACM Press, 2017: 58-62.
- [14] Eusuff M M, Lansey K E. Optimization of water distribution network design using the shuffled frog leaping algorithm [J]. Journal of Water Sources Planning and Management, 2003, 129(3): 210-225.
- [15] Dehdeleh V, Ebrahimi A, Nia A B. Improved shuffled frog leaping algorithm by using orthogonal experimental design [C]//Proc of the 2nd International Conference of Signal Processing and Intelligent Systems. Piscataway, NJ: IEEE Press, 2016: 1-5.